

# IECD 2C2024 - Trabajo Práctico

En el trabajo siguiente, estudiaremos el test «de rango signado de Wilcoxon», un test no paramétrico para la mediana de una distribución simétrica. Tendrán que implementarlo de manera compatible con la implementación nativa de *R*, `wilcox.test`, y luego calcular su potencia para alternativas puntuales por el método de *bootstrap*. Para ello, introduciremos primero

- S3, el paradigma OOP<sup>1</sup> más viejo de *R* (sí, hay varios) y
- las condiciones de validez y propiedades generales del test de Wilcoxon.

## Condiciones de entrega y aprobación

El presente escrito es un apunte sobre OOP y el test de Wilcoxon, con preguntas prácticas diseminadas en medio. Cada pregunta correcta vale tantos puntos como se menciona entre paréntesis en cada una, y **para aprobar es necesario contar con 65 de 114 puntos**.

**El TP ha de resolverse en grupos de 3 integrantes.** El formato de entrega consistirá de dos archivos subidos a través del campus,

- `informe-<apellido1>-<apellido2>-<apellido3>.pdf`, un informe *en formato PDF* páginas contestando las preguntas teóricas, y
- `codigo-<apellido1>-<apellido2>-<apellido3>.R`, un *script* de *R* con las respuestas a las preguntas de código, siguiendo estrictamente el formato requerido en cada una.

Tanto el informe como el código se evaluarán con especial énfasis en la **claridad y concisión de exposición, y prolijidad en la presentación**. El código, además, se evaluará de manera automática, a través de una serie de casos de prueba secretos (pero análogos a los que se ofrecen en cada pregunta), que deberán ejecutarse con éxito.

Los gráficos que se piden, deben ser incluidos en el *informe*, y no es necesario incluir el código utilizado para realizarlos.

Hemos decidido eliminar la restricción de longitud, pero por favor, eviten usarlo como licencia de curso para la perorata.

Para el informe pueden usar el procesador de texto que deseen, aunque sugerimos utilizar formatos amigables a la expresión científica, como LaTeX<sup>2</sup>, RMarkdown o Typst<sup>3</sup>.

La idea del trabajo es que *aprendan unos temas poco comunes*, no que sufran: si no contestan todas las preguntas, está bien. Si quieren saltarse algunas en una primera pasada y volver más tarde, también.

¡Mucha suerte!

---

<sup>1</sup>Programación Orientada a Objetos, por sus siglas en inglés

<sup>2</sup>Si no conocen un buen editor, Overleaf es una excelente primera opción

<sup>3</sup>¡Este TP está escrito en Typst!

## Bibliografía 📖

Lamentablemente la enorme mayoría de la bibliografía de calidad de estos temas está en inglés. A quien se le dificulte la lectura, le recomendamos acudir a cualquier buen traductor o *chatbot* respetable para asistirlo en el proceso.

### OOP en R

Esta exposición está recortada arbitrariamente y traducida al castellano de «[Advanced R](#)», de Hadley Wickham y equipo, que recomiendo enfáticamente en su totalidad para quienes deseen profundizar sus conocimientos de R. En particular, les sugerimos leer:

- Cap. 12 - Tipos Base
- Cap. 13 - S3 hasta 13.5 «Object Styles» inclusive

Si no tienen ninguna noción de R más allá de «hice unas cositas sueltas para IECD», recomendamos además leer someramente los capítulos 2 («Nombres y Valores») y 3 («Vectores»).

Un recurso un poco más viejo pero repleto de amor y odio por las particularidades de R es [R Inferno](#) en el Séptimo Círculo, «Tripping on Object Orientation», cubre someramente y con perspectiva histórica estos mismos temas.

### Lectura de verano ☀️🌴

Para quien desee lectura de verano, los siguientes libros disponibles *online* son de extrema utilidad para el cientista de datos profesional:

- [Hands-on Programming With R](#), una excelente guía general al lenguaje, y luego
- [R para Ciencia de Datos](#) (¡en español!) y su [original en inglés](#), más enfocados en las particularidades de la *data saiens*.

### Test de Wilcoxon de Rango Signado

Una introducción somera se puede encontrar en Wikipedia: [Wilcoxon signed-rank test](#). El recurso canónico para tests basados en rangos, es «Statistical Inference Based on Ranks», de Thomas P. Hettmansperger (§2, p. 29, 1984, [pdf](#), [6MB](#)). En este último está basada la exposición que sigue. Además,

- El «libro de recetas de cocina»<sup>4</sup> por excelencia es *Practical Nonparametric Statistics*, de W.J. Conover (p.352, 1999, [djvu](#) - [9MB](#), [pdf](#), [124MB](#)).
- Un recurso más moderno del mismo Thomas Hettmansperger, es *Robust Nonparametric Statistical Methods*, de T.P. Hettmansperger y J.W. McKean (p. 38, 2010, [pdf](#), [5MB](#)).

### Notación

- $[n] = \{1, \dots, n\}$  es el conjunto de los primeros  $n$  números naturales
- $C = A/B = \{x : x \in A \wedge x \notin B\}$  es la operación de sustracción de conjuntos,
- la **negrita** ( $\mathbf{X}, \mathbf{a}, \mathbf{1}$ ) denota valores vectoriales, y fuente «normal» para escalares
- usamos mayúsculas ( $\mathbf{Y}, \mathbf{Z}$ ) para elementos aleatorios y minúsculas ( $y, \mathbf{a}$ ) para no-aleatorios<sup>5</sup>.
- $1\{A\}$  es la función indicadora, que vale 0 cuando  $A$  es Falso y 1 cuando  $A$  es Verdadero
- Dado un conjunto  $A$ ,  $\#A$  denotará su cardinalidad
- $X \perp Y$  indica que las v.a. (potencialmente multivariadas)  $X$  e  $Y$  son independientes entre sí

---

<sup>4</sup>en inglés, *cookbook*, un texto de referencia para practicantes con buenos ejemplos y escasa teoría

<sup>5</sup>sean conocidas o no

## OOP en R

### Breve intro opinionada

Que los computólogos me juzguen por las barbaridades que estoy por decir. Muy resumidamente, en el paradigma de «Programación Orientada a Objetos», un programa se compone de una serie de interacciones entre *objetos*, que además de poseer ciertos *atributos*, tiene *métodos* que les permiten interactuar entre sí y con otras *clases* de objetos.

En R, hay no una sino al menos 3 «dialectos» para expresarse «en objetos»: S3, S4 y R6<sup>6</sup>, de los cuales «S3» es el (a) el más viejo, y (b) el que está *por todas partes* en la implementación base de R que todos amamos y sufrimos por partes iguales. Por ello, **nos concentraremos en S3**.

En OOP, un *objeto* es una *instancia* de una *clase* general que se comporta de cierta manera. R tiene una implementación espectacularmente simple de esta convención:

**Definición 1** (Objeto en S3): Un objeto es una *estructura* con un atributo de nombre `class` cuyo valor define la clase del objeto.

```
> objs <- list(mtcars, 1:5, sum, lm(mpg ~ cyl, mtcars), t.test)
> for (obj in objs) { print(class(obj)) }
[1] "data.frame"
[1] "integer"
[1] "function"
[1] "lm"
[1] "function"
```

**Pregunta 1** (3 pts.): ¿Qué clase tienen los siguientes vectores: `c(T, F)`, `c(T, F, 1)` y `c(T, F, 1, "1")`? ¿Qué cree que está sucediendo?

*Respuesta:* Los vectores tienen clase (o «tipo») `logical`, `numeric` y `character`, respectivamente.

«The output type is determined from the highest type of the components in the hierarchy `NULL < raw < logical < integer < double < complex < character < ...`»  
— `help(c)`

- Como `T(RUE)` y `F(ALSE)` son ambos de tipo lógico, el primer vector es lógico.
- Como `1` es `numeric` (para que sea un entero habría que escribir `1L`), el vector entero es de tipo `numeric` (o `double`), el tipo del componente más alto en la jerarquía.
- Finalmente, como `"1"` es una cadena de caracteres, el vector entero será de tipo `character`.



---

<sup>6</sup>Wickham explica bien los orígenes de `c/u` en los capítulos antedichos.

Una estructura puede ser *cualquier cosa*, prácticamente, y el atributo se setea con la sintaxis clásica.

```
> lucas <- 1:5
> class(lucas)
[1] "integer"
> attr(lucas, "class") <- "pato"
> class(lucas)
[1] "pato"
```

Una manera más común de definir la clase de un objeto, es usar el constructor `structure`, que hace literalmente lo que necesitamos, asignarle atributos arbitrarios a un objeto cualquiera.

```
> donald <- structure(6:10, class="pato")
> class(donald)
[1] "pato"
```

¿Es peligrosa esta filosofía? Sí y no: *puede serlo*, pero sólo si insistimos en asignare clase «petunias» al método `mean` o clase «pato» a un vector de enteros, cosas por el estilo. Aquí, la filosofía de R es «mientras no te taladres los pies, un taladro es una herramienta y no un arma»: exponer las «entrañas» del lenguaje tan abiertamente, hace posible que la comunidad de desarrolladores implemente nuevas clases y métodos con un mínimo de conocimiento sobre sus convenciones.

### Métodos «genéricos»

En R, casi todos los métodos de «base» son *genéricos*, que pueden adaptar su comportamiento según la *clase* del primer parámetro que reciben. La convención, *a grosso modo*, dice que cuando se llama un método genérico (como `print`<sup>7</sup>) con primer argumento `obj`, `print(obj)`, R averigua la clase del objeto, `cls <- class(obj)`, y chequea si está definido el método `print.cls`,

- Si lo está, devuelve `print.cls(obj)`, y
- si no, «sigue la cadena de herencia» hasta encontrar una coincidencia o salir por la versión `default`.

Luego, podemos tomar confusas decisiones de diseño, que funcionan de pelos:

```
> print.pato <- function(pato) { "cuac" }
> print(lucas)
[1] "cuac"
```

`sloop::s3_dispatch(llamada)`<sup>8</sup> devuelve una sinopsis de cómo S3 «despachó» la llamada `llamada` al de la clase correspondiente, según su cadena de herencia:

```
> sloop::s3_dispatch(print(lucas))
=> print.pato
```

---

<sup>7</sup>De `help("print")`: «print prints its argument and returns it invisibly (via `invisible(x)`). **It is a generic function which means that new printing methods can be easily added for new classes.**»

<sup>8</sup>`sloop`, de «S Language OOP», es una librería desarrollada por Wickham et al para simplificar el trabajo con los sistemas de clases en R. Como a cualquier librería, a `sloop` se la instala con `install.packages("sloop")` y se la importa con `library(sloop)`.

```
* print.default
> s3_dispatch(mean(1:5))
  mean.integer
  mean.numeric
=> mean.default
```

De igual manera se consigue que `plot(density(1:500))` «automáticamente» plotee la estimación de la densidad por núcleos, sin más:

```
> s3_dispatch(plot(density(1:500)))
=> plot.density
* plot.default
```

**Pregunta 2** (3 pts.): ¿Qué clase tiene `density`? ¿Y `density(1:500)`? ¿Dónde está la diferencia?

*Respuesta:* `density` tiene clase `function`, mientras que `density(1:500)` tiene clase `density`. La documentación es clara: `density` es una función (`function`), y el valor que retorna (que se obtiene al invocarla, con o sin parámetros), es un objeto de clase `density`). De la ayuda,

### Description

The (S3) generic **function** `density` computes kernel density estimates.

### Value

If `give.Rkern` is true, the number  $R(K)^9$ , otherwise **an object with class «density»** whose underlying structure is a list containing ...

— [`help\(density\)`](#)



### Introspección: `methods`

Para conocer los métodos a los que sabe despachar cierto genérico `gen`, basta con llamar a `methods("gen")`. Si se quiere conocer todos los métodos asociados con la clase "`cls`", se invoca `methods(class="cls")`:

```
> methods("plot")[1:8]
[1] "plot,ANY-method" "plot,color-method" "plot.acf" "plot.data.frame"
[5] "plot.decomposed.ts" "plot.default" "plot.dendrogram" "plot.density"
> methods(class="density")
[1] coerce      initialize  plot        print       show        slotsFromS3
see '?methods' for accessing help and source code
```

<sup>9</sup>el «ancho de banda canónico»

Las funciones `sloop::s3_methods_generic(gen)` y `s3_methods_class(cls)` retornan la misma información, ordenada más sistemáticamente.

**Pregunta 3** (3 pts.): ¿A cuántas clases sabe despachar el genérico `print`? ¿Con cuántos métodos cuenta `density`, además de `plot`?

*Respuesta:* ¡Pregunta trampa accidental! En R «base», `print` sabe despachar a 230 (!) clases distintas, lo que se puede obtener evaluando `length(methods("print"))`. Ahora bien, si importamos `sloop` veremos que ahora `nrow(s3_methods_generic("print"))`<sup>10</sup> devuelve 248, y `length(methods("print"))` también, porque la librería importa también sus propias clases, que sabe imprimir proficientemente. Si seguimos importando librerías, el número puede seguir creciendo.

Según `methods(class="density")`, la *clase* `density` (no la función) tiene seis métodos disponibles: `print`, `plot`, `coerce`, `show`, `initialize`, `slotsFromS3`. Según `s3_methods_class("density")`, sin embargo, sólo cuenta con 2: `print`, `plot`. La diferencia radica en que los otros 4 son una especie de «meta-métodos», disponibles para todas las clases de S3 (y S4) para manipularse a sí mismas, y `sloop` no los considera «propios» de una clase específica. ■

### Fijando ideas: `mi.t.test`

Supongamos que contamos con una muestra  $\mathbf{X} = (X_1, \dots, X_n)$  de tamaño  $n$  con distribución  $X_i \stackrel{\text{iid}}{\sim} \text{Normal}(\mu, \sigma^2)$  y deseamos testear

$$H_0 : \mu = \mu_0 \quad \text{versus} \quad H_1 : \mu \neq \mu_0$$

Para fijar ideas, supongamos que para nosotros tanto  $\mu$  como  $\sigma^2$  son desconocidos cuando en realidad,  $X_i \stackrel{\text{iid}}{\sim} \text{Normal}(1, 1)$ , contamos con  $n = 30$  y nos interesa testear  $\mu_0 = 0, \alpha = 0.05$ . En estas circunstancias, el «test T» es el adecuado. En R,

```
# Genero la muestra
mu <- 1
sigma_sq <- 1
n <- 30
X <- rnorm(n, mean = mu, sd = sqrt(sigma_sq))
# Ejecuto el test
mu_0 <- 0
alfa <- 0.05
test_t <- t.test(
  X,
  alternative = "two.sided",
  mu = mu_0,
  conf.level = 1 - alfa
)
```

---

<sup>10</sup>Como `s3_methods_generic` devuelve un «data frame», la cantidad de filas se obtiene con `nrow` y no `length`.

**Pregunta 4** (3pts.): Lea `help(unclass)` y conteste: ¿Qué devuelve `class(unclass(test_t))`? ¿Por qué?

*Respuesta:* `class(unclass(test_t))` devuelve **list**, pues

«`unclass` returns (a copy of) its argument with its class attribute removed.»

— `help(unclass)`

Al quitarle el atributo `class="htest"`, nos queda el «objeto pelado» sobre el que se construyó un objeto de tipo `htest`, que resulta ser una lista como se ve - una vez más - en la ayuda:

### Value

A **list** with class «`htest`» containing the following components: ...

— `help(t.test)`



No es muy difícil reimplementar la lógica detrás de un `test T` a dos colas como ésta con los conocimientos adquiridos este cuatrimestre. Respetando la convención de nombres de la salida de `t.test`, nos queda:

```
mi.t.test <- function(x, mu0 = 0, alfa = 0.05) {  
  n <- length(x)  
  parameter <- n - 1  
  estimate <- mean(x)  
  stderr <- sd(x) / sqrt(n)  
  statistic <- (estimate - mu0) / stderr  
  conf.int <- estimate + qt(c(alfa / 2, 1 - alfa / 2), df = parameter) *  
  stderr  
  p.value.izq <- pt(statistic, df = parameter)  
  p.value <- 2 * min(p.value.izq, 1 - p.value.izq)  
  list(  
    parameter=parameter,  
    estimate=estimate,  
    stderr=stderr,  
    statistic=statistic,  
    conf.int=conf.int,  
    p.value=p.value  
  )  
}
```

La desgracia, es que el `t.test` de R tiene una presentación por defecto bastante informativa:

```
> t.test(X)
```

```

One Sample t-test

data: X
t = 4.6001, df = 29, p-value = 7.697e-05
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 0.4391649 1.1422807
sample estimates:
mean of x
0.7907228

```

... y mucho mejor que la de nuestro test:

```

> (mi_test_t <- mi.t.test(X))
$parameter
[1] 29

$estimate
[1] 0.7907228

$stderr
[1] 0.1718916

$statistic
[1] 4.600124

$conf.int
[1] 0.4391649 1.1422807

$p.value
[1] 7.697055e-05

```

¿Será que `t.test` es instancia de una clase que `print` entiende? ¡Pues claro!

```

> help("s3_dispatch")
> s3_dispatch(print(R_test_t))
=> print.htest
* print.default
> s3_dispatch(print(mi_test_t))
print.list
=> print.default

```

En lugar de escribir de cero una función específica de `print` para `mi.t.test`, podemos pararnos en los hombros de gigantes. Le daremos a `mi.t.test` la clase de `t.test`, y veremos de respetar sus convenciones, de manera que podamos utilizar la ya bien pulida `print.htest`<sup>11</sup>. Vamos de nuevo:

---

<sup>11</sup>que dicho sea de paso, considera *unos cuantos casos*: [link al código](#)



```

is.scalar <- function(x) { is.numeric(x) && length(x) == 1 }
mi.t.test <- function(x, mu = 0, conf.level = 0.95) {
  stopifnot(is.numeric(x))
  stopifnot(is.scalar(mu))
  stopifnot(is.scalar(conf.level), (conf.level > 0), (conf.level < 1))
  alfa <- 1 - conf.level
  n <- length(x)
  rv <- list(
    parameter = c(df = n - 1),
    estimate = c(`mean of x` = mean(x)),
    stderr = sd(x) / sqrt(n),
    null.value = c(mean = mu),
    alternative = "two.sided",
    method = "One Sample t-test",
    # Stack Overflow: How to convert variable (object) name into String
    # https://stackoverflow.com/a/14577878
    data.name = deparse(substitute(x))
  )
  rv$statistic <- setNames((rv$estimate - mu) / rv$stderr, "t")
  rv$conf.int <- rv$estimate + qt(c(alfa / 2, 1 - alfa/2), df = rv$parameter)
  * rv$stderr
  attr(rv$conf.int, "conf.level") <- conf.level
  pval_izq <- pt(rv$statistic, df = rv$parameter)
  rv$p.value <- 2 * min(pval_izq, 1 - pval_izq)
  structure(rv, class = "htest")
}

```

Y ahora resulta que:

```

> mi.t.test(X)

One Sample t-test

data: X
t = 4.6001, df = 29, p-value = 7.697e-05
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 0.4391649 1.1422807
sample estimates:
mean of x
0.7907228

> stopifnot(capture.output(t.test(X)) == capture.output(mi.t.test(X)))

```

**Observación 1** (stopifnot): Cuando uno desea «testear» condiciones en medio de un programa, stopifnot es sumamente útil: recibe varias expresiones, y si alguna *no* evalúa a TRUE, devolverá un error. Aquí arriba, nos dice que el output de t.test y mi.t.test son exactamente iguales.

# Test de Wilcoxon de rango signado para una muestra

## Introducción

Cuando «la distribución  $F$  de  $X$  pertenece a la familia normal  $\mathcal{N}$ »<sup>12</sup>, el test  $T$  que vimos durante la cursada es uniformemente más potente para hipótesis de la forma:

$$H_0 : \mu \leq \mu_0 \quad \text{versus} \quad H_1 : \mu > \mu_0$$

$$H_0 : \mu \geq \mu_0 \quad \text{versus} \quad H_1 : \mu < \mu_0$$

cunando  $\sigma^2$  es desconocido. En el «mundo real», el supuesto de normalidad es una hipótesis sumamente ceñida, en tanto consigna la distribución de  $X$  a un *modelo paramétrico* específico.

Una familia bastante amplia de distribuciones, está dada por «el conjunto de distribuciones absolutamente continuas, con mediana igual a 0»

$$\Omega_0 = \left\{ F : F \text{ absolutamente continua, } F(0) = \frac{1}{2} \right\}$$

Cuando  $X \sim G(x) = F(x - \theta)$ ,  $F \in \Omega_0$ , el «test del signo»<sup>13</sup>, resulta ser uniformemente más potente para testear la mediana ( $G(\theta) = F(\theta - \theta) = F(0) = \frac{1}{2}$ ) según

$$H_0 : \theta \leq 0 \quad \text{versus} \quad H_1 : \theta > 0$$

, aunque es cierto que no existen *muchos* tests de nivel dado para esta familia tan amplia. Esta clase de tests, se considera «no paramétricos»<sup>14</sup>, en tanto la familia de distribuciones en la que funcionan *no admiten obvias parametrizaciones*.

Una familia «a medio camino» entre  $\mathcal{N}$  y  $\Omega_0$ , es el de las distribuciones simétricas:

**Definición 2** (distribución simétrica): una v.a.  $X$  con densidad  $f$  se dice «simétrica alrededor de  $\theta$ » si  $f(\theta + \delta) = f(\theta - \delta) \forall \delta > 0$

Esto nos permite definir  $\Omega_s \subset \Omega_0$ , el conjunto de las distribuciones simétricas alrededor del 0:

$$\Omega_s = \{F : F \in \Omega_0, F(t) = 1 - F(-t) \forall t \in \mathbb{R}\}$$

Cuando  $X \sim F \in \Omega_0$ , decimos que « $X$  (o  $F$ ) es simétrica alrededor del cero». Ahora,  $\mathbf{X} = (X_1, \dots, X_n)$  será una muestra aleatoria tomada de  $G(x) = F(x - \theta)$ ,  $F \in \Omega_s$ , donde la mediana es única, está bien definida y es igual a  $\theta$ . Sin pérdida de generalidad, nos interesarán, entonces, tests de la forma

$$H_0 : \theta \leq 0 \quad \text{versus} \quad \theta > 0$$

$$H_0 : \theta \geq 0 \quad \text{versus} \quad \theta < 0$$

**Observación 2:** Para testear  $H_0 : \theta \leq \theta_0$ , basta con definir  $Y_i = X_i - \theta_0$  y realizar los test definidos aquí arriba sobre  $\mathbf{Y}$

---

<sup>12</sup>es decir, que  $X_i \sim F \in \mathcal{N} = \{F_X : X \sim \text{Normal}(\mu, \sigma^2), \mu \in \mathbb{R}, \sigma^2 \in (0, \infty)\}$ . Diremos indistintamente que  $X$  ó  $F$  pertenecen a la familia  $\mathcal{N}$

<sup>13</sup>confer Práctica 5, ejercicio 22

<sup>14</sup>*nopa*, para los amigos

**Observación 3:** Si definimos  $\mathcal{N} = \{F_X : X \sim \text{Normal}(0, \sigma^2), \sigma^2 > 0\} \Rightarrow \mathcal{N} \subset \Omega_s \subset \Omega_0$ .

Wilcoxon (1945, [link](#)) planteó un test bastante ingenioso para estas situaciones, que (aunque no lo probaremos), resulta ser uniformemente más potente para distribuciones en  $\Omega_s$ .

### Motivación: diseños experimentales apareados

Existen casos completamente válidos en los lo único que sabemos acerca de una distribución es que es simétrica, y nos interesa testear su mediana. Dicho esto, existe un escenario muy común donde la distribución bajo la hipótesis nula pertenece a  $\Omega_s$ .

Consideremos la situación en la que tenemos dos tratamientos de interés,  $A$  y  $B$ <sup>15</sup>, que se pueden aplicar a sujetos de una población de interés, y estamos interesados en una respuesta particular después de que se hayan aplicado estos tratamientos.

Sea  $X$  la respuesta de un sujeto después de que se le haya aplicado el tratamiento  $A$  y sea  $Y$  la medida correspondiente para un sujeto después de que se le haya aplicado el tratamiento  $B$ . La hipótesis nula natural será

$$H_0 : \text{No hay diferencia en la distribución de } X \text{ e } Y.$$

$$\text{es decir, } H_0 : F_X = F_Y$$

Supongamos que tenemos una manera de aparear los sujetos de un estudio. Por ejemplo, disponemos de gemelos idénticos para un estudio en sujetos humanos, compañeros de camada para un estudio en sujetos animales o las dos mitades de una misma pared exterior de una casa para un estudio sobre la durabilidad de pinturas de exterior. En el *diseño por pares* (o apareado), se seleccionan aleatoriamente  $n$  *pares* de sujetos de la población de interés. Dentro de cada par, un miembro se asigna aleatoriamente al tratamiento  $A$  mientras que el otro recibe el tratamiento  $B$ .

Este diseño experimental da como resultado una muestra de pares  $(X_1, Y_1), \dots, (X_n, Y_n)$ . A pesar de que este experimento tiene un vector de respuestas de dimensión dos, el interés está puesto en las diferencias obtenidas:  $D_1 = X_1 - Y_1, \dots, D_n = X_n - Y_n$ , y las  $D_1, \dots, D_n$  se convierten en la *única* muestra de interés para decidir si los tratamientos se diferencian significativamente.

Bajo la hipótesis nula de que no hay diferencia en el tratamiento (es decir, que la distribución de  $X$  es la misma que la distribución de  $Y$ ) junto con la asignación aleatoria dentro de cada par a recibir el tratamiento  $A$  o el  $B$  obtenemos una distribución simétrica de las diferencias.

**Pregunta 5** (5 pts.): Bajo  $H_0 : F_X = F_Y$  (los tratamientos son indistinguibles) y asumiendo que la asignación de cada individuo al tratamiento se realiza de forma aleatoria, la distribución conjunta  $F_{X,Y}$  del vector aleatorio  $(X, Y)$  es la misma que la del vector  $(Y, X)$ ; es decir,  $F_{X,Y} = F_{Y,X}$ . Probar que entonces la distribución de  $D = X - Y$  es simétrica alrededor del cero.

---

<sup>15</sup>Entendido de forma amplia, un placebo - o cualquier otro procedimiento de referencia o «control» - también es un tratamiento, y este mismo *setup* permite describir diseños del tipo «tratamiento / control».

*Respuesta:* Si  $F_{X,Y} = F_{Y,X}$ , se sigue que  $\Pr(X \leq x, Y \leq y) = \Pr(Y \leq x, X \leq y)$  y por lo tanto  $X, Y$  son variables aleatorias intercambiables. Luego,

$$\begin{aligned} F_D(d) &= \Pr(D \leq d) = \Pr(X - Y \leq d) = \Pr(Y - X \leq d) \\ &= \Pr(-d \leq X - Y) = \Pr(-d \leq D) = 1 - \Pr(D \leq -d) \\ &= 1 - F_D(-d) \end{aligned}$$

y por ende  $F_D \in \Omega_s$ , y  $D$  está simétrica distribuida alrededor del 0). ■

Habiendo expuesto razonablemente la relevancia de la familia  $\Omega_s$ , en particular en el contexto de evaluación empírica de «tratamientos» en diseños muestrales «apareados», pasemos a describir el test de Wilcoxon en sí.

### Descripción del test

De aquí en más, consideraremos únicamente el escenario de una sola muestra  $X$ , con distribución  $G$  simétrica.

Consideremos una muestra aleatoria  $\mathbf{X} = (X_1, \dots, X_n)$ ,  $X_i \stackrel{\text{iid}}{\sim} G(t) = F(t - \theta)$ . Deseamos encontrar un test para la «locación»<sup>16</sup>  $\theta$ .

$$H_0 : \theta = 0 \quad \text{versus} \quad H_1 : \theta > 0$$

, con  $F \in \Omega_s$ .

Antes de introducir el estadístico a emplear, definiremos algunas funciones:

**Definición 3** (Función signo):

$$\text{signo}(x) : \mathbb{R} \rightarrow \{-1, 0, +1\}, \text{signo}(x) = \begin{cases} -1 & \text{si } x < 0 \\ 0 & \text{si } x = 0 \\ +1 & \text{si } x > 0 \end{cases}$$

**Definición 4** (Función Rango): Sea  $\mathbf{X} = (X_1, \dots, X_n)$  una muestra aleatoria, y  $X^{(1)}, \dots, X^{(n)}$  la misma muestra, ordenada en forma no decreciente. Llamaremos el *rango*<sup>17</sup> de  $X_i$ , al índice de la posición que ocupa en la muestra ordenada:

$$R_i = \text{Rango}(X_i \mid \mathbf{X}) = j \Leftrightarrow X_i = X^{(j)}$$

**Observación 4:** Una manera de calcular el rango de una observación, es

$$R_i = \#\{X : X \leq X_i, X \in \mathbf{X}\} = \sum_{j=1}^n \mathbb{1}\{X_j \leq X_i\}$$

Es decir, la función Rango toma como input un vector  $\mathbf{x}$ , y devuelve otro vector  $\mathbf{r}$  que es una permutación de  $[n] = \{1, \dots, n\}$ , donde el  $i$ -ésimo elemento indica la cantidad de elementos de  $\mathbf{x}$  menores o iguales a  $x_i$ , o lo que es lo mismo, su posición ordinal.

<sup>16</sup>En distribuciones simétricas, las dos locaciones clásicas, media y mediana, coinciden.

<sup>17</sup>como en el *rango* militar, donde «general» está por encima de «capitán», que está por encima de «oficial», etc.

Llamemos  $|\mathbf{X}| = (|X_1|, |X_2|, \dots, |X_n|)$  al vector de valores absolutos de  $\mathbf{x}$ , y  $R_i = \text{Rango}(|X_i|)$  el rango de  $|X_i|$  en  $|\mathbf{X}|$ . Ahora sí, podemos presentar una primera versión del estadístico del test de rangos signados de Wilcoxon:

$$T(\mathbf{X}) = \sum_{i=1}^n \text{signo}(X_i) R_i$$

donde por ser  $X_i$  v.a. absolutamente continuas e independientes entre sí,

$$\Pr(X_i = 0) = 0 \quad \forall i \in [n]$$

$$\Pr(X_i = X_j) = 0 \quad \forall i, j \in [n], i \neq j$$

de manera que no hay empates ni  $\text{signo}(X_i) = 0$ .

**Pregunta 6** (3 pts.): Muestre que los siguientes estadísticos:

$$T^+ = \sum_{i=1}^n \mathbb{1}\{X_i > 0\} R_i$$

$$T^- = \sum_{i=1}^n \mathbb{1}\{X_i < 0\} R_i$$

son equivalentes a  $T$  (i.e., muestre que a partir de cualquiera de los 3 y conociendo  $n$ , se pueden computar exactamente los otros dos). *Sugerencia: calcule  $T^+ + T^-$*

*Respuesta:* Sabemos que necesariamente,  $\sum_{i=1}^n R_i = \sum_{i=1}^n i = \frac{n(n+1)}{2}$ . Luego,

$$\begin{aligned} T^+ + T^- &= \sum_{i=1}^n \mathbb{1}\{X_i > 0\} R_i + \sum_{i=1}^n \mathbb{1}\{X_i < 0\} R_i \\ &= \sum_{i=1}^n \mathbb{1}\{X_i > 0\} R_i + \mathbb{1}\{X_i < 0\} R_i = \sum_{i=1}^n R_i \\ T^+ + T^- &= \frac{n(n+1)}{2} \end{aligned}$$

Además,  $T = T^+ - T^-$ , así que para todo  $n$  y valor observado  $t$  de  $T^+$ ,

$$T^+ = t; \quad T^- = \frac{n(n+1)}{2} - t; \quad T = 2t - \frac{n(n+1)}{2}$$

■

De las tres formas, la que más comúnmente se usa para definir el test, es  $T^+$  será la que consideremos de aquí en más. Nuestro test será de la forma

$$\phi(\mathbf{X}) = \mathbb{1}\{T^+ > k\}$$

, de manera rechazaremos la hipótesis nula cuando la suma de los rangos de los  $X_i > 0$  sea lo suficientemente grande, dándole peso a la hipótesis alternativa de que  $\theta > 0$ .

Para facilitar el estudio de la distribución de  $T^+$  bajo  $H_0$ , introduciremos una última - lo juro - variante en la notación.

**Definición 5** (Antirrangos): Sean  $R_1, \dots, R_n$  los rangos correspondientes a un vector  $\mathbf{m} = m_1, \dots, m_n$ , o sea que  $R_i = j \Leftrightarrow m_i = m^{(j)}$ . Diremos entonces que el  $j$ -ésimo *antirrangos* es igual a  $i$ . En otras palabras, el antirrangos es «la inversa» del rangos:  $D_j = i$  si el  $j$ -ésimo elemento de la muestra ordenada es el  $i$ -ésimo en la muestra original:

$$D_j = i \Leftrightarrow R_i = j$$

Por ejemplo, si  $\mathbf{m} = (m_1, m_2, m_3)$ , con  $m_2 < m_3 < m_1$ , resulta que

$$\begin{aligned} R_1 &= R(m_1 \mid \mathbf{m}) = 3 & D_1 &= 2 \text{ pues } m^{(1)} = m_2 \\ R_2 &= R(m_2 \mid \mathbf{m}) = 1 & D_2 &= 3 \text{ pues } m^{(2)} = m_3 \\ R_3 &= R(m_3 \mid \mathbf{m}) = 2 & D_3 &= 1 \text{ pues } m^{(3)} = m_1 \end{aligned}$$

Habiendo definido los antirrangos, podemos reescribir el estadístico  $T^+$  de la siguiente manera:

$$T^+ = \sum_{i \in [n]} \mathbb{1}\{X_i > 0\} R_i = \sum_{D_j \in [n]} \mathbb{1}\{X_{D_j} > 0\} R_{D_j} = \sum_{j \in [n]} W_j \times j$$

donde  $W_j = \mathbb{1}\{X_{D_j} > 0\} = \frac{\text{signo}(X_{D_j}) + 1}{2}$  y por definición,  $R_{D_j} = R(|X_{D_j}|) = j$ .

### Distribución de $T^+$ bajo la hipótesis nula

Ahora sí estamos en condiciones de estudiar la distribución de  $T^+$  bajo  $H_0$ .

**Pregunta 7** (5 pts.): Demuestre que bajo  $H_0$ ,  $|X_i|$  es independiente de  $\text{signo}(X_i)$ .

*Sugerencia: utilice sus conocimientos sobre  $F_X$  bajo  $H_0$ .*

*Respuesta:*

Escribamos «la distribución conjunta» de  $|X_i|$  y  $\text{signo}(X_i)$  como  $g(x, s) = \Pr(|X_i| \leq x, \text{signo}(X_i) = s)$ . Como  $F_X \in \Omega_s \Rightarrow F_X(0) = \frac{1}{2}, F_X(x) = 1 - F_X(-x)$ . Sin pérdida de generalidad, asumamos un signo positivo:

$$\begin{aligned} g(x, 1) &= \Pr(|X_i| \leq x, \text{signo}(X_i) = 1) = \Pr(-x \leq X_i \leq x, X_i > 0) \\ &= \Pr(0 < X_i \leq x) = F_X(x) - F_X(0) = F_X(x) - \frac{1}{2} \\ &= \frac{1}{2}[2F_X(x) - 1] = \frac{1}{2}[F_X(x) - (1 - F_X(x))] = \frac{1}{2}[F_X(x) - F_X(-x)] \\ &= \Pr(\text{signo}(X_i) = 1) \times \Pr(|X_i| \leq x) \end{aligned}$$

Un resultado análogo muestra que  $g(x, -1)$  también se factoriza en  $\Pr(\text{signo}(X_i) = -1)$  y  $\Pr(|X_i| \leq x)$ , con lo cual la probabilidad conjunta de  $|X_i|$  y  $\text{signo}(X_i)$  es *siempre* igual al producto de sus probabilidades marginales, y por ende son independientes. ■

**Pregunta 8** (3 pts.): A partir del resultado anterior, pruebe que bajo  $H_0$  los vectores de rangos  $\mathbf{R} = (R_1, \dots, R_n)$  y antirrangos  $\mathbf{D} = (D_1, \dots, D_n)$  correspondientes a  $|\mathbf{X}|$  son independientes del vector de signos  $\mathbf{S} = (\text{signo}(X_1), \dots, \text{signo}(X_n))$  de la muestra original  $\mathbf{X}$ .

*Respuesta:* Consideremos los vectores

$$|\mathbf{X}| = (|X_1|, \dots, |X_n|)$$

$$\mathbf{S} = (S_1, \dots, S_n) = (\text{signo}(X_1), \dots, \text{signo}(X_n))$$

$$\mathbf{R} = (R_1, \dots, R_n) = (\text{Rango}(|X_1|), \dots, \text{Rango}(|X_n|))$$

$$\text{y } \mathbf{D} = (D_1, \dots, D_n) = (\text{Antirrango}(R_1), \dots, \text{Antirrango}(R_n))$$

1. Por definición, tanto  $S_i$  como  $|X_i|$  sólo dependen de  $X_i$ . Luego, para todo  $i \neq j$ ,  $i, j \in [n]$ , sabemos que (a)  $S_i \perp |X_j|$ . Además, por la respuesta a la Pregunta 7, sabemos que (b)  $S_i \perp |X_i|$ . Conjuntamente, (a) y (b) implican que todos los elementos de  $\mathbf{S}, |\mathbf{X}|$  son independientes «uno con uno», y por ende  $\mathbf{S} \perp ||\mathbf{X}||$ .
2. El rango  $R_i$  del módulo de la  $i$ -ésima observación  $|X_i|$  sí que depende de los valores de  $|X_j|$ ,  $j \neq i$ , pero al considerar el vector completo,  $\mathbf{R}$  sólo depende de  $|\mathbf{X}|$  a través de alguna función  $f$ . Como  $\mathbf{S} \perp ||\mathbf{X}||$  y  $\mathbf{R} = f(|\mathbf{X}|)$ . Por lo tanto, se sigue que  $\mathbf{S} \perp \mathbf{R}$ .
3. Análogamente a (2), el vector de antirrangos  $\mathbf{D}$  es una función del vector  $\mathbf{R}$ :

$$\mathbf{D} = g(\mathbf{R}) = g(f(|\mathbf{X}|))$$

, y sólo dependen de  $|\mathbf{X}|$  vía  $\mathbf{R}$ . Como  $\mathbf{S} \perp ||\mathbf{X}||$ , entonces también  $\mathbf{S} \perp \mathbf{D}$ . ■

**Pregunta 9** (5 pts.): Pruebe que bajo  $H_0 : \theta = 0, F \in \Omega_s$ , las v.a.  $W_j = \mathbb{1}\{X_{D_j} > 0\}$  distribuyen según

$$W_1, \dots, W_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}\left(\frac{1}{2}\right)$$

*Sugerencia:* Utilice la Ley de la Probabilidad Total de  $\mathbf{W}$  sobre los posibles valores de  $\mathbf{D}$ , y utilice los resultados previos para operar y factorizar  $\Pr(\mathbf{W} = \mathbf{w}) = \prod_{j \in [n]} \Pr(W_j = w_j)$ .

*Respuesta:* Fijando sin pérdida de generalidad  $j = 1$ , es fácil dar con la distribución de  $W_1$ , por ejemplo:

$$\Pr(W_1 = 1) = \Pr(\{X_{D_1} > 0\} = 1) = \Pr(X_{D_1} > 0) = \frac{1}{2}$$

$$\Pr(W_1 = 0) = \Pr(\{X_{D_1} > 0\} = 0) = \Pr(X_{D_1} < 0) = \frac{1}{2}$$

ya que  $X_i$  es simétrica alrededor de 0 para todo  $i \in [n]$ . Esto alcanza para mostrar que las  $W_j$  están *idénticamente* distribuidas. Como  $\mathbf{W}$  depende tanto de  $|\mathbf{X}|$  como de  $\mathbf{D}$ , la independencia es un poco más delicada.

Sean  $\mathbf{w} = (w_1, \dots, w_n) \in \{0, 1\}^n$ . Llamemos  $\mathcal{P}([n])$  al conjunto de permutaciones de los primeros  $n$  naturales  $[n]$ : éste es el *soporte* de  $\mathbf{D}$ <sup>18</sup>. Luego, bajo  $H_0 : \theta = 0, F \in \Omega_s$ , tenemos que

$$\begin{aligned} \Pr(\mathbf{W} = \mathbf{w}) &= \sum_{\mathbf{d} \in \mathcal{P}([n])} \Pr(\mathbf{W} = \mathbf{w} \mid \mathbf{D} = \mathbf{d}) \times \Pr(\mathbf{D} = \mathbf{d}) \\ &= \sum_{\mathbf{d} \in \mathcal{P}([n])} \Pr(\{X_{D_1} > 0\} = w_1, \dots, \{X_{D_n} > 0\} = w_n \mid \mathbf{D} = \mathbf{d}) \times \Pr(\mathbf{D} = \mathbf{d}) \\ &= \sum_{\mathbf{d} \in \mathcal{P}([n])} \Pr(\{X_{d_1} > 0\} = w_1, \dots, \{X_{d_n} > 0\} = w_n) \times \Pr(\mathbf{D} = \mathbf{d}) \end{aligned}$$

Por ser simétrica alrededor del cero,

$$\Pr(\{X_{d_1} > 0\} = 0) = \Pr(X_{d_1} < 0) = \frac{1}{2} \quad \text{y} \quad \Pr(\{X_{d_1} > 0\} = 1) = \Pr(X_{d_1} > 0) = \frac{1}{2}$$

así que  $\Pr(\{X_{d_1} > 0\} = w_1, \dots, \{X_{d_n} > 0\} = w_n) = \left(\frac{1}{2}\right)^n$ . Luego,

$$\begin{aligned} \Pr(\mathbf{W} = \mathbf{w}) &= \sum_{\mathbf{d} \in \mathcal{P}([n])} \left(\frac{1}{2}\right)^n \times \Pr(\mathbf{D} = \mathbf{d}) \\ \Pr(\mathbf{W} = \mathbf{w}) &= \left(\frac{1}{2}\right)^n \underbrace{\sum_{\mathbf{d} \in \mathcal{P}([n])} \Pr(\mathbf{D} = \mathbf{d})}_{=1} \\ \Pr(\mathbf{W} = \mathbf{w}) &= \left(\frac{1}{2}\right)^n = \prod_{i \in [n]} \Pr(W_i = w_i) \end{aligned}$$

y resulta que la distribución conjunta de  $\mathbf{W}$  es igual al producto de las distribuciones individuales de cada  $W_i, i \in [n]$ . Luego, los  $W_i$  son independientes entre sí y la prueba está completa. ■

De los ítems anteriores, se desprende que bajo  $H_0$ , **la distribución de  $T^+$  es una suma de variables aleatorias independientes, aunque no idénticamente distribuidas.**

**Observación 5:** Lo único que utilizamos para hallar la distribución bajo  $H_0$  de  $T^+$  fue que  $X_i \stackrel{\text{iid}}{\sim} F(x - \theta), F \in \Omega_s$ . Como la distribución de  $T^+$  será la misma para *cualquier*  $F \in \Omega_s$ , se dice que  $T^+$  es de *distribución libre* («distribution-free») bajo  $H_0$

### Distribución exacta de $T^+$

Aunque la distribución de  $T^+$  no tiene forma cerrada, su cómputo exhaustivo no es particularmente difícil. Para simplificar la notación, omitiremos la dependencia de la probabilidad a  $H_0$  hasta próximo aviso.

Sabemos que  $T^+$  es una v.a. discreta con soporte en los enteros desde 0 hasta  $\frac{n(n+1)}{2}$ . Queremos hallar

<sup>18</sup>el conjunto exhaustivo de valores que puede tomar  $\mathbf{D}$



$$p_n(t) = \Pr(T^+ = t) = \Pr\left(\sum_{j \in [n]} (W_j \times j) = t\right)$$

Llamemos  $A_{n,t} = \{\mathbf{w} : T^+ = t\}$  al conjunto posibles valores de  $\mathbf{w} = (w_1, \dots, w_n) \in \{0, 1\}^n$  tal que

$$T^+ = \sum_{j \in [n]} (w_j \times j) = \sum_{j: w_j=1} j = t$$

. Ya sabemos de la respuesta a Pregunta 9 que  $\Pr(\mathbf{W} = \mathbf{w}) = \frac{1}{2^n} \forall \mathbf{w} \in \{0, 1\}^n$ , y luego

$$\Pr(T^+ = t) = \Pr(\mathbf{w} \in A_{n,t}) = \frac{\#A_{n,t}}{2^n}$$

donde según,  $\#A_t$  es la cardinalidad de A «conjunto potencia» de todas las  $2^n$  combinaciones posibles de signos.

**Observación 6:** Existe una equivalencia natural entre los vectores  $\mathbf{w} = (w_1, \dots, w_n)$  y los conjuntos  $s(\mathbf{w}) = \{i : w_i = 1\}$  que conservan únicamente los índices no-nulos de  $\mathbf{w}$ , de manera que  $A_{n,t}$  y  $S_{n,t} = \{s(\mathbf{w}) : \mathbf{w} \in A_{n,t}\}$  tienen la misma cardinalidad. Luego, podemos escribir

$$p_n(t) = \frac{\#S_{n,t}}{2^n}$$

Cuando  $n = 4$  por ejemplo, resulta que

| $t$ | $S_{4,t}$                   | $\#S_{4,t}$ | $p_4(t)$ |
|-----|-----------------------------|-------------|----------|
| 0   | $\{\emptyset\}$             | 1           | 1/16     |
| 1   | $\{\{1\}\}$                 | 1           | 1/16     |
| 2   | $\{\{2\}\}$                 | 1           | 1/16     |
| 3   | $\{\{3\}, \{1, 2\}\}$       | 2           | 2/16     |
| 4   | $\{\{4\}, \{1, 3\}\}$       | 2           | 2/16     |
| 5   | $\{\{1, 4\}, \{2, 3\}\}$    | 2           | 2/16     |
| 6   | $\{\{2, 4\}, \{1, 2, 3\}\}$ | 2           | 2/16     |
| 7   | $\{\{3, 4\}, \{1, 2, 4\}\}$ | 2           | 2/16     |
| 8   | $\{\{1, 3, 4\}\}$           | 1           | 1/16     |
| 9   | $\{\{2, 3, 4\}\}$           | 1           | 1/16     |
| 10  | $\{\{1, 2, 3, 4\}\}$        | 1           | 1/16     |

**Pregunta 10** (5pts.): Reproduzca la tabla de Observación 6 para  $n = 5$

*Respuesta:*

| $t$ | $S_{5,t}$                                      | $\#S_{5,t}$ | $p_5(t)$ |
|-----|------------------------------------------------|-------------|----------|
| 0   | $\{\emptyset\}$                                | 1           | 1/32     |
| 1   | $\{\{1\}\}$                                    | 1           | 1/32     |
| 2   | $\{\{2\}\}$                                    | 1           | 1/32     |
| 3   | $\{\{3\}, \{1, 2\}\}$                          | 2           | 2/32     |
| 4   | $\{\{4\}, \{1, 3\}\}$                          | 2           | 2/32     |
| 5   | $\{\{5\}, \{1, 4\}, \{2, 3\}\}$                | 3           | 3/32     |
| 6   | $\{\{1, 5\}, \{2, 4\}, \{1, 2, 3\}\}$          | 3           | 3/32     |
| 7   | $\{\{2, 5\}, \{3, 4\}, \{1, 2, 4\}\}$          | 3           | 3/32     |
| 8   | $\{\{3, 5\}, \{1, 2, 5\}, \{1, 3, 4\}\}$       | 3           | 3/32     |
| 9   | $\{\{4, 5\}, \{1, 3, 5\}, \{2, 3, 4\}\}$       | 3           | 3/32     |
| 10  | $\{\{1, 4, 5\}, \{2, 3, 5\}, \{1, 2, 3, 4\}\}$ | 3           | 3/32     |
| 11  | $\{\{2, 4, 5\}, \{1, 2, 3, 5\}\}$              | 2           | 2/32     |
| 12  | $\{\{3, 4, 5\}, \{1, 2, 4, 5\}\}$              | 2           | 2/32     |
| 13  | $\{\{1, 3, 4, 5\}\}$                           | 1           | 1/32     |
| 14  | $\{\{2, 3, 4, 5\}\}$                           | 1           | 1/32     |
| 15  | $\{\{1, 2, 3, 4, 5\}\}$                        | 1           | 1/32     |

■

**Pregunta 11** (5 pts.): Muestre que  $T^+$  es simétrica alrededor de  $\frac{n(n+1)}{4}$

*Respuesta:* Sólo de observar las tablas, vemos que cuando  $n = 4$ ,  $T^+$  es simétrica alrededor de  $5 = \frac{4(4+1)}{4}$  y cuando  $n = 5$ ,  $T^+$  es simétrica alrededor de  $7.5 = \frac{5(5+1)}{4}$ .

Trataremos de mostrarlo para cualquier  $n$ , usando que para cada conjunto de índices  $s$  que suma  $t$ , su complemento  $s^c$  suma exactamente  $\frac{n(n+1)}{2} - t$ , y por ende  $p_n$  es simétrica alrededor de  $\frac{n(n+1)}{2}$ .

Tomemos un elemento  $s(w) = \{i : w_i = 1\}$  arbitrario, llamémoslo  $s_0$  y consideremos su complemento respecto a  $[n]$ ,

$$s_0^c = [n]/s_0$$

$s_0^c$  y  $s_0$  son disjuntos, y su unión es exactamente  $[n]$ . Luego, si la suma de los elementos de  $s_0$  es  $t_0$ ,  $s_0 \in S_{n,t_0}$ ,

$$\sum_{i \in [n]} i = \sum_{i \in s_0} i + \sum_{i \in s_0^c} i \Rightarrow \frac{n(n+1)}{2} = t_0 + \sum_{i \in s_0^c} i \Rightarrow \sum_{i \in s_0^c} i = \frac{n(n+1)}{2} - t_0$$

y resulta que  $s_0^c \in S_{n,t_0^c}$ , con  $t_0^c = \frac{n(n+1)}{2} - t_0$ . Para esta equivalencia no impusimos ninguna condición a  $n$  ni  $t_0$ , por lo cual vale para todo  $s \subseteq [n]$ . Se sigue entonces que  $S_{n,t_0^c} = \{s^c : s \in S_{n,t_0}\}$  y por lo tanto  $\#S_{n,t_0^c} = \#S_{n,t_0}$ .

$$p_n(t_0) = \frac{\#S_{n,t_0}}{2^n} = \frac{\#S_{n,t_0^c}}{2^n} = \frac{\#S_{n,\frac{n(n+1)}{2}-t_0}}{2^n} = p_n\left(\frac{n(n+1)}{2} - t_0\right)$$

y  $p_n$  resulta simétrica alrededor de

$$\frac{t_0 + \left(\frac{n(n+1)}{2} - t_0\right)}{2} = \frac{n(n+1)}{4}$$

■

*Respuesta:* (esbozo alternativa 1) Si se mira con cuidado, el argumento por la distribución exacta de  $T^+$  no depende en ningún momento del signo positivo; luego, un razonamiento idéntico lleva a concluir que la probabilidad puntual de  $T^-$  también es  $p_n(t)$ . De Pregunta 6 sabemos que  $T^+ + T^- = \frac{n(n+1)}{2}$ . Luego,  $\forall t \in \left[\frac{n(n+1)}{2}\right]$ ,

$$\Pr(T^+ = t) = \Pr(T^- = n(n+1)/2 - t) = \Pr(T^+ = n(n+1)/2 - t)$$

Y resulta que TT es simétrica alrededor de  $\frac{n(n+1)}{4}$

■

*Respuesta:* (esbozo alternativa 2) Usando recursión,

- Cuando  $n = 0$ ,  $T^+$  vale 0 con probabilidad 1, y  $T^+$  es trivialmente simétrica.
- Cuando  $n = 1$ ,  $T^+$  es simétrica alrededor de  $\frac{1(1+1)}{4} = \frac{1}{2}$ , pues

$$p_1(t) = \begin{cases} 1/2 & \text{si } t \in \{0, 1\} \\ 0 & \text{caso contrario} \end{cases}$$

Si podemos probar que «si  $T^+$  es simétrica para  $m$ , entonces es simétrica para  $m + 1$ », y encontramos alrededor de qué valor se da la simetría, habremos completado la prueba.

Pues bien, la fórmula recursiva que sigue sirve exactamente para ello.

■

### Fórmula recursiva para $n$ «grande»

Ya para un valor moderado como  $n = 20$ ,  $2^n = 1.048.576$ : el crecimiento exponencial de los valores posibles de  $\mathbf{W}$  vuelve inconcebible el cómputo «exhaustivo» de  $p_{T^+}$ . El hecho de que  $T^+$  sea simétrica simplificaría algo las cuentas, pero no demasiado. Sin embargo, existe una fórmula recursiva particularmente interesante:

Supongamos que  $s \in S_{n,t}$ , de manera que  $\sum_{x \in s} x = t$ . O bien  $n \in s$ , o bien  $n \notin s$ :

- si  $n \notin s$ , entonces  $s \subseteq [n-1]$  y suma  $t$ ; luego  $s \in S_{n-1,t}$ ,
- si  $n \in s$ , entonces  $s - \{n\} \subseteq [n-1]$  y suma  $t - n$ ; luego  $s - \{n\} \in S_{n-1,t-n}$ .

Como ambas son mutuamente excluyentes, y se cumplen para cada  $s \in S_{n,t}$ , si llamamos  $u_n(t)$  a la cardinalidad de  $S_{n,t}$ ,

$$u_n(t) = u_{n-1}(t) + u_{n-1}(t - n)$$

Con los límites de la recursión en

$$u_0(t) = \begin{cases} 1 & \text{si } t = 0 \\ 0 & \text{caso contrario} \end{cases}$$

$$u_n(t) = 0 \quad \text{si } t < 0 \quad \text{ó } t > \frac{n(n+1)}{2}$$

Luego,

$$p_n(t) = \frac{\#S_{n,t}}{2^n} = \frac{u_n(t)}{2^n}$$
$$p_n(t) = \frac{1}{2} \left[ \frac{u_{n-1}(t)}{2^{n-1}} + \frac{u_{n-1}(t-n)}{2^{n-1}} \right]$$
$$p_n(t) = \frac{1}{2} [p_{n-1}(t) + p_{n-1}(t-n)]$$

**Pregunta 12** (8 pts.): Programe la recursión  $u_n(t)$  en R. Llámela `particiones`, y dele dos argumentos,  $t, n$ , ambos enteros.

```
particiones <- function(t, n) {  
  # su código aquí  
}
```

La función debe pasar al menos los siguientes tests:

```
stopifnot(  
  particiones(t=3, n=4) == 2,  
  particiones(t=24, n=12) == 67,  
  particiones(t=55, n=10) == 1,  
  particiones(t=45, n=30) == 1938  
)
```

*Respuesta:*

```
particiones <- function(t, n) {  
  if (n == 0) {  
    return(ifelse(t == 0, 1, 0))  
  } else if ((t < 0) | (t > n * (n + 1) / 2)) {  
    return(0)  
  } else {  
    return(particiones(t, n - 1) + particiones(t - n, n - 1))  
  }  
}
```

■

**Pregunta 13** (8 pts.): Usando `particiones`, implemente `dTmas(x, n)` y `pTmas(x, n)` que toman un vector de enteros `x` y un escalar `n`, y den, respectivamente, la función de probabilidad puntual y la función de distribución de  $T^+$  bajo  $H_0$  en cada valor de `x`.

```
dTmas <- function(x, n) {
  ret <- vector(mode = "numeric", length = length(x))
  for (i in seq_along(x)) {
    # Su código aquí
  }
  return(???)
}
pTmas <- function(x, n) { "repita el patrón de dTmas" }
```

Al menos los siguientes casos de test deben pasar:

```
n <- 15
t <- 34
stopifnot(
  dTmas(24, 12) == 67 / 2 ^ 12,
  dTmas(0:10, 4) == c(1, 1, 1, 2, 2, 2, 2, 2, 1, 1, 1) / 16,
  sum(dTmas(0:21, 6)) == 1,
  dTmas(0:2, 55) == 2 ^ -55,
  dTmas(t, n) == dTmas(n * (n + 1) / 2 - t, n),
  pTmas(t, n) == 1 - pTmas(n * (n + 1) / 2 - (t + 1), n)
)
```

*Nota: ¡Ojo! `particiones` espera un escalar como primer argumento `t`, mientras que `pTmas` y `dTmas` esperan vectores.*

*Respuesta:*

```
dTmas <- function(x, n) {
  ret <- vector(mode = "numeric", length = length(x))
  for (i in seq_along(x)) {
    ret[i] <- particiones(x[i], n)
  }
  return(ret / 2 ^ n)
}

pTmas <- function(x, n) {
  ret <- vector(mode = "numeric", length = length(x))
  for (i in seq_along(x)) {
    ret[i] <- sum(dTmas(0:x[i], n))
  }
  return(ret)
}
```



*Respuesta:* (sobre performance)

Aunque correctas y fáciles de entender, estas versiones son muy poco *performantes*. `dTmas` está OK para calcular un valor puntual de  $p_n(t)$ , pero si se desea calcular varios valores de  $t$  para un mismo  $n$  (que es como `pTmas` llama a `dTmas`), se podrían reutilizar los resultados de llamadas a `particiones(t, n)`. Esta técnica se conoce como «cacheado» o «memoización», y vale la pena estudiarla por separado. En R, un buen punto de partida para esto es la ayuda del operador `<-` que deberán buscar ingresando `?<-` en la consola.

En `pTmas`, podemos calcular una sola vez todos los valores de `dTmas` necesarios, guardarlos en una variable, y luego reutilizarlos. Noten cuánto más rápida se siente esta versión:

```
pTmas <- function(x, n) {  
  dTmas_n <- dTmas(0:(max(x)), n)  
  ret <- vector(mode = "numeric", length = length(x))  
  for (i in seq_along(x)) {  
    ret[i] <- sum(dTmas_n[1:(x[i] + 1)])  
  }  
  return(ret)  
}
```

■

### **mi.wilcox.test**

Ahora sí, estamos en condiciones de implementar el test de Wilcoxon de rango signado. Repasemos: Para una muestra aleatoria

$$\mathbf{X} = (X_1, \dots, X_n), X_i \stackrel{\text{iid}}{\sim} F(x - \theta) \forall i \in [n], F \in \Omega_s$$

, deseamos testear:

- ('two.sided') igual contra distinto:  $H_0 : \theta = \theta_0$  versus  $H_0 : \theta \neq \theta_0$
- ('greater') menor o igual contra mayor:  $H_0 : \theta \leq \theta_0$  versus  $H_0 : \theta > \theta_0$
- ('less') mayor o igual contra menor:  $H_0 : \theta \geq \theta_0$  versus  $H_0 : \theta < \theta_0$

**Pregunta 14** (15 pts.): Programe `mi.wilcox.test`, una función con la misma clase que `wilcox.test`, que toma los siguientes parámetros (siguiendo la firma de `wilcox.test`):

- `x`, un vector numérico con la muestra  $X$ ,
- `alternative`, un escalar de tipo "character" representando las hipótesis a testear (una de `c("two.sided", "greater", "less")`),
- `mu`, un escalar numérico representando  $\theta_0$ , el valor de la mediana bajo la hipótesis nula. y devuelve un objeto de clase "htest", con (al menos) atributos `statistic`, `p.value` y `alternative` equivalentes a los salida de `wilcox.test`.

No hace falta reportar una región de rechazo, basta con el p-valor. Al menos el siguiente caso de prueba debe pasar:

```
set.seed(1234)
n <- 20
X <- rnorm(n)
theta0 <- -1
alternative <- "greater"

R_wilcox <- wilcox.test(X, alternative=alternative, mu = theta0)
mi_wilcox <- mi.wilcox.test(X, alternative=alternative, mu = theta0)
stopifnot(
  identical(mi_wilcox$statistic, R_wilcox$statistic),
  identical(mi_wilcox$alternative, R_wilcox$alternative),
  isTRUE(all.equal(mi_wilcox$p.value, R_wilcox$p.value)),
  identical(class(R_wilcox), class(mi_wilcox))
)
```

*Sugerencia: Consulte la ayuda de `match.arg` para manipular el valor de `alternative`.*

*Respuesta:*

```
mi.wilcox.test <- function(x, alternative = c("two.sided", "less",
"greater"), mu = 0) {
  stopifnot(is.numeric(x))
  stopifnot(is.scalar(mu))
  n <- length(x)
  X <- X - mu # centro los datos en la mediana bajo H0
  rv <- list(
    alternative = match.arg(alternative),
    statistic = setNames(sum(rank(abs(X))[X > 0]), "V")
  )
  pval.izq <- pTmas(rv$statistic, n)
  pval.der <- 1 - pTmas(rv$statistic - 1, n)
  if (alternative == "greater") {
    rv$p.value <- pval.der
  } else if (alternative == "less") {
    rv$p.value <- pval.izq
  }
```

```

} else { # alternative == "two.sided"
  rv$p.value <- 2 * min(pval.izq, pval.der)
}
return(structure(rv, class = "htest"))
}

```

■

## Distribución asintótica

Aunque  $T^+$  es una combinación lineal de variables independientes e idénticamente distribuidas entre sí (las  $W_j$ ), cada una está pesada por un coeficiente distinto (los  $j \in [n]$ ), por lo cual la versión del Teorema Central del Límite que conocemos no nos servirá.

**Pregunta 15** (5 pts.): Bajo  $H_0$ , ¿Cuánto vale  $\mathbb{E}(T^+)$ ? ¿Y  $\text{Var}(T^+)$ ?

*Respuesta:* Bajo  $H_0$ ,

$$\begin{aligned}
 \mathbb{E}(T^+) &= \mathbb{E}\left(\sum_{j \in [n]} W_j \times j\right) = \sum_{j \in [n]} \mathbb{E}(W_j \times j) = \sum_{j \in [n]} \mathbb{E}(W_1 \times j) \\
 &= \mathbb{E}(W_1) \sum_{j \in [n]} j = \frac{1}{2} \cdot \frac{n(n+1)}{2} = \frac{n(n+1)}{4} \\
 \text{Var}(T^+) &= \text{Var}\left(\sum_{j \in [n]} W_j \times j\right) = \sum_{j \in [n]} \text{Var}(W_j \times j) = \sum_{j \in [n]} \text{Var}(W_1 \times j) \\
 &= \text{Var}(W_1) \sum_{j \in [n]} j^2 = \frac{1}{4} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{n(n+1)(2n+1)}{24}
 \end{aligned}$$

■

La «condición de Lindeberg» nos dota de una forma un poco más general del T.C.L., que ahí adaptamos del Apéndice «A9» de Hettmansperger (1984)<sup>19</sup>

**Teorema 1** (TCL de Lindeberg): Sean  $W_1, \dots, W_n$  v.a. i.i.d. con  $\mathbb{E}(W_1) = 0$ ,  $\text{Var}(W_1) = \sigma^2$ ,  $0 < \sigma^2 < \infty$ . Defínase  $S = \sum_{i=1}^n a_i W_i / \sqrt{n}$ . Si

$$\frac{\max_i |a_i|}{\sqrt{\sum_{i=1}^n a_i^2}} \rightarrow 0$$

entonces  $\frac{S}{\sqrt{\text{Var}(S)}} \xrightarrow{\mathcal{D}} \text{Normal}(0, 1)$ , con  $\text{Var}(S) = \sigma^2 \left( \sum_{i=1}^n a_i^2 \right) / n$ .

<sup>19</sup>cf. página 301 del libro o p. 317 del PDF para la prueba



**Pregunta 16** (8 pts.): Dé la distribución asintótica de  $T^+$

*Respuesta:* Consideremos una sucesión de estimadores indexados en el tamaño muestral  $n$ ,  $T_n^+$ . Sabemos ya que  $T_n^+ = \sum_{j \in [n]} j \cdot W_j$ , donde los  $W_j$  no tienen esperanza nula, pero sí tienen varianza constante. Consideremos entonces  $V_i = W_i - E(W_i) = W_i - 1/2$ :

$$T_n^+ = \sum_{j \in [n]} j \cdot \left( V_j + \frac{1}{2} \right) = \sum_{j \in [n]} j \cdot V_j + \frac{n(n+1)}{4}$$

donde  $\forall j \in [n]$ ,

$$\mathbb{E}(V_j) = \mathbb{E}\left(W_j - \frac{1}{2}\right) = \frac{1}{2} - \frac{1}{2} = 0$$

$$\text{y } \text{Var}(V_j) = \text{Var}\left(W_j - \frac{1}{2}\right) = \text{Var}(W_j) = \frac{1}{4} = \sigma^2 \in (0, \infty)$$

Tomando  $a_j = j \cdot \sqrt{n}$  tal que  $j = a_j/\sqrt{n}$ , tenemos que

$$S = \sum_{i=1}^n a_i W_i / \sqrt{n} = \sum_{j \in [n]} j \cdot V_j$$

y por ende  $T_n^+ = S + \frac{n(n+1)}{4}$ , ó  $S = T^+ - \mathbb{E}(T^+)$  como uno esperaría. Además,

$$\begin{aligned} \frac{\max_j |a_j|}{\sqrt{\sum_{j=1}^n a_j^2}} &= \frac{\max_j |j/\sqrt{n}|}{\sqrt{\sum_{j=1}^n (j/\sqrt{n})^2}} = \frac{\overbrace{\max_j j}^{=n}}{\cancel{\sqrt{n}}} \cdot \frac{\cancel{\sqrt{n}}}{\sqrt{\sum_{j=1}^n j^2}} = \frac{n}{\sqrt{\frac{n(n+1)(2n+1)}{6}}} \\ &= \frac{\sqrt{6}}{\cancel{\sqrt{\frac{n}{n}}}} \cdot \underbrace{\frac{1}{\sqrt{\frac{n+1}{n}}}}_{<1} \cdot \frac{1}{\sqrt{2n+1}} < \sqrt{\frac{6}{2n+1}} \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

Así que  $\frac{S}{\sqrt{\text{Var}(S)}} \xrightarrow{\mathcal{D}} \text{Normal}(0, 1)$ . Operando sobre  $\text{Var}(S)$  vemos que:

$$\text{Var}(S) = \text{Var}\left(\sum_{j \in [n]} j \cdot V_j\right) = \sum_{j \in [n]} j^2 \overbrace{\text{Var}(V_j)}^{=\frac{1}{4} \forall j \in [n]} = \frac{n(n+1)(2n+1)}{4 \cdot 6} = \text{Var}(T^+)$$


y finalmente resulta que

$$\frac{T_n^+ - \mathbb{E}(T_n^+)}{\sqrt{\text{Var}(T_n^+)}} \xrightarrow{\mathcal{D}} \text{Normal}(0, 1)$$

■

**Pregunta 17** (8 pts.): Fije  $n_1 = 4, n_2 = 10, n_3 = 20$ . Para cada  $n$ , realice un gráfico de barras con la probabilidad puntual *exacta* de  $T^+$  (vélgase de dTmas) y superpóngale una línea con la densidad asintótica esperada. ¿Coinciden razonablemente? ¿En toda la distribución, en el centro, en las colas? ¿A partir de qué  $n$ ? ¿Se le ocurre alguna corrección sencilla para los  $n$  pequeños?

*Respuesta:*



Dos decisiones a tomar:

1. si graficar la  $T^+$  «original», o su versión «estandarizada»,  $\frac{T^+ - \mathbb{E}(T^+)}{\sqrt{\text{Var}(T^+)}}$ .
2. Cómo convertir una densidad continua (dnorm) a una probabilidad discreta (dTmas).

En este gráfico, respecto a

1. elegimos graficar  $T^+$  estandarizada para mantener un eje X comparable en todos los los gráficos.
2. Tomamos la «sencilla» decisión de elegir una grilla equiespaciada a intervalos  $\delta$ ,  $\mathbf{g} = (g_1, \dots, g_m)^{20}$  que cubre con 10% de margen el rango de  $T^+$ , y calcular la probabilidad puntual a graficar en  $g_j$  como  $\delta \cdot f_{\mathcal{N}}(g_j)$ , donde  $f_{\mathcal{N}}$  es la densidad Normal(0,1).

Una sofisticación, potencialmente importante para  $n$  pequeños, sería graficar en  $g_j$  la probabilidad de  $[f_{\mathcal{N}}(g_j + \frac{\delta}{2}) + f_{\mathcal{N}}(g_j - \frac{\delta}{2})]/2$ , centrando el intervalo en  $g_j$  y aproximando la densidad con un paralelogramo en lugar de un rectángulo.

En ningún caso hay sesgos sistémicos, pero para  $n = 4$  la aproximación es tal vez demasiado burda para ser de utilidad práctica. Aún para  $n = 20$  la aproximación normal muestra una ligera sobreestimación en el entorno de  $t = 0$ , una ligera sobreestimación en  $(-2\sigma, +2\sigma)$ , y - a esta escala - una aproximación bastante certera en las colas.

<sup>20</sup>Es decir,  $g_i = g_{i-1} + \delta$

## Distribución bajo la alternativa vía *bootstrap*

Bajo  $H_1$ ,  $F$  no es simétrica alrededor de 0 sino de algún otro valor, con lo cual los rangos no serán independientes de los signos, y la distribución del estadístico  $T^+$  no cuenta con forma cerrada.

Sin embargo, conociendo el proceso generador de los datos (o DGP<sup>21</sup>), es posible calcular la potencia para una alternativa puntual, con el procedimiento de *bootstrap* paramétrico. Asuma el ambiente de test ya habitual,  $X_i \stackrel{\text{iid}}{\sim} F(x - \theta)$ ,  $F \in \Omega_s$ , y queremos testear a nivel menor o igual a  $\alpha$ <sup>22</sup>:

$$H_0 : \theta = 0 \text{ versus } H_1 : \theta = \theta_1 > 0$$

El test resultará

$$\phi(\mathbf{X}) = \mathbb{1}\{T^+ > k^*\}, \mathbb{E}_0(\phi) = \alpha^* \leq \alpha$$

donde elegimos  $k^*$  para maximizar la potencia del test, respetando el nivel  $\leq \alpha$ .

Sea ahora  $H(x) = F(x - \theta_1)$  la verdadera distribución del DGP, simétrica y con mediana igual a  $\theta_1$ . Si el DGP es conocido, el siguiente procedimiento nos da un método para estimar la potencia  $\pi_\phi(\theta_1)$ :

1. Genere  $m$  muestras de tamaño  $n$  de la distribución  $H$ ; llamémoslas  $\mathbf{Y}_1, \dots, \mathbf{Y}_m$
2. Compute  $T^+(\mathbf{Y}_i) \forall i \in [m]$ ; guarde los resultados en un vector.
3. El estimador por bootstrap de  $\pi_\phi(\theta_1)$  está dado por

$$\widehat{\pi}_\phi(\theta_1) = \widehat{\mathbb{E}}_{\theta_1}(\phi) = m^{-1} \sum_{i=1}^m \mathbb{1}\{T^+(\mathbf{Y}_i) \geq k^*\}$$

**Observación 7:** En este *setup*, el procedimiento de bootstrap es «paramétrico», en tanto la distribución del DGP está parametrizada y por ende podemos *samplear* de ella directamente. A diferencia del procedimiento visto en clase en el que había que estimar  $\hat{\theta}_1$  y luego samplear de  $F_{\hat{\theta}_1} = F(x - \hat{\theta}_1)$ , aquí el enunciado provee el  $\theta_1$  real, así que su estimación es innecesaria y podemos samplear directamente de  $H(x) = F(x - \theta_1)$ . Por lo demás, el procedimiento es el mismo.

---

<sup>21</sup>*Data Generating Process*, por sus siglas en inglés

<sup>22</sup>Recuerden que como el estadístico  $T^+$  es discreto, el nivel que alcance nuestro test no será exactamente  $\alpha$ , sino el mayor  $\alpha^* \leq \alpha$  que la distribución permita.

**Pregunta 18** (13 pts.): Los siguientes datos fueron generados por  $D = \text{Normal}(1, 1)$ ,  $n = 12$ :

```
set.seed(1984)
n <- 12
theta1 <- 1
sigma_sq <- 1
X <- rnorm(n, mean=theta1, sd=sqrt(sigma_sq))
```

Compute  $\phi_w$ , el test de Wilcoxon de rango signado de nivel menor o igual a  $\alpha = 0.05$  para las hipótesis:

$$H_0 : \theta = 0 \quad \text{versus} \quad H_1 : \theta > 0$$

A continuación, fije  $\theta_1 = 1, m = 10.000$  y estime por bootstrap la potencia  $\widehat{\pi_{\phi_w}}(\theta_1)$ .

*Respuesta:* El paso (1), generar las muestras, es trivial. En el paso (2), no es recomendable usar `mi.wilcox.test` para computar el estadístico, ya que la función carga con la tarea aquí innecesaria de calcular el p-valor correspondiente. Mejor, hacer una función sencilla `Tmas(x)` que compute el estadístico a partir de una muestra. Para el paso (3), es necesario conocer  $k^*$ , donde por convención definimos la región de rechazo RR con un límite cerrado,  $[k^*, \frac{n(n+1)}{2}]$ .

```
m <- 10000
theta0 <- 0
alfa <- 0.05
Tmas <- function(x) { sum(rank(abs(x))[x > 0]) }
boot.Tmas <- vector(mode = "numeric", length = m)
for (i in seq.int(m)) {
  Y <- rnorm(n, mean = theta1, sd = sigma_sq)
  boot.Tmas[i] <- Tmas(Y)
}
suma.n <- (n*(n+1))/2
pTobs <- cumsum(dTmas(0:suma.n, n)) # más rápido que pTmas(...)
idx <- which.max(pTobs > 1 - alfa)
# idx es el índice del primer elemento tal que pTobs > 1 - alfa
# pTobs[idx] es la acumulada hasta k = idx-1; pTmas(idx-1, n) > 1 - alfa
# la RR comenzará - inclusive - en el entero sgte a (idx - 1), que es
# `idx`
k.wil <- idx
alfa.wil <- sum(dTmas(k.star:suma.n, n))
pot.boot.wil <- mean(boot.Tmas >= k.star)
```

Resulta entonces que  $k_w^* = 61$ ,  $\alpha_w^* = 0.04614...$  y  $\widehat{\pi_{\phi_w}}(1) \approx 0.9324$ . ■

**Pregunta 19** (8 pts.): Compute para las mismas hipótesis y condiciones de Pregunta 18,  $\phi_n$ , un test para el valor de la media (y mediana) de v.a.i.i.d. con varianza conocida, según  $D$ .

Calcule (analíticamente, sin estimar) la potencia  $\pi_{\phi_n}(\theta_1)$ . Compute además  $\phi_s$ , el test del signo para las mismas hipótesis y estime por bootstrap,  $\widehat{\pi_{\phi_s}}(\theta_1)$ . Compare y contraste los resultados obtenidos. ¿Es el test t efectivamente el más potente? ¿Por cuánto?

(0pts., sólo para valientes) Sin asumir varianza conocida, hay que recurrir al «test t». Describa  $\phi_t$ , el «test t» correspondiente a esta situación, calcule su potencia para la alternativa  $\theta_1$  e inclúyalo en la comparación con  $(\phi_w, \phi_n, \phi_s)$ .

*Sugerencia: considere la distribución «t de Student no-central». Para el cálculo de potencia, de necesitarlo, sí puede utilizar el verdadero  $\sigma$ .*

*Nota: Al igual que con  $\phi_w$ , tenga cuidado de proveer un test del signo  $\phi_s$  exacto<sup>23</sup> de nivel tan cercano a  $\alpha = 0.05$  como pueda, pero sin pasarse.*

*Respuesta:* Considerando las mismas hipótesis de siempre, sabemos que  $\phi_n$  depende del estadístico  $Z = \sqrt{n} \frac{\bar{X} - \theta_0}{\sigma}$ , que bajo  $H_0$  tiene distribución Normal(0, 1). Si  $z_\alpha$  es el cuantil que para una Normal(0, 1) acumula probabilidad  $\alpha$  a derecha, resulta:

$$\begin{aligned}\phi_n(\mathbf{X}) &= \mathbb{1}\{Z(\mathbf{X}) \geq z_\alpha\} \\ \mathbb{E}_0(\phi_n) &= \mathbb{E}_0(\mathbb{1}\{Z > z_\alpha\}) = \Pr_0(Z \geq z_\alpha) = \alpha\end{aligned}$$

Para calcular la potencia bajo la alternativa, consideremos que

$$\begin{aligned}Z(\mathbf{X}) \geq z_\alpha &\Leftrightarrow \sqrt{n} \frac{\bar{X} - \theta_0}{\sigma} \geq z_\alpha \\ &\Leftrightarrow \sqrt{n} \frac{\bar{X} - \theta_0}{\sigma} + \sqrt{n} \frac{\theta_0 - \theta_1}{\sigma} \geq z_\alpha + \sqrt{n} \frac{\theta_0 - \theta_1}{\sigma} \\ &\Leftrightarrow \sqrt{n} \frac{\bar{X} - \theta_1}{\sigma} \geq z_\alpha + \sqrt{n} \frac{\theta_0 - \theta_1}{\sigma}\end{aligned}$$

y bajo  $H_1$ ,  $\sqrt{n} \frac{\bar{X} - \theta_1}{\sigma} \sim \text{Normal}(0, 1)$ . Luego, si  $\Phi$  es la función de distribución de una normal estándar, resulta que:

$$\begin{aligned}\pi_{\phi_n}(\theta_1) &= \mathbb{E}_1(\mathbb{1}\{Z > z_\alpha\}) = \Pr_1(Z \geq z_\alpha) = \Pr_1\left(\sqrt{n} \frac{\bar{X} - \theta_1}{\sigma} \geq z_\alpha + \sqrt{n} \frac{\theta_0 - \theta_1}{\sigma}\right) \\ \pi_{\phi_n}(\theta_1) &= 1 - \Phi\left(z_\alpha + \sqrt{n} \frac{\theta_0 - \theta_1}{\sigma}\right)\end{aligned}$$

Reemplazando con nuestros datos, obtenemos

$$\pi_{\phi_n}(\theta_1) \approx 1 - \Phi\left(1.6449 + \sqrt{12} \frac{0 - 1}{\sqrt{1}}\right) \approx 1 - \Phi(-1.8192) \approx 0.9656$$

<sup>23</sup>En la Práctica 5 Ej. 22 se da un test del signo asintótico. Si se le complica deducir el equivalente exacto, en Hettmansperger (1984) la sección §1.2 describe «El test del Signo y Su Distribución».

```

k.norm <- qnorm(alfa, lower.tail=FALSE)
delta <- sqrt(n) / sqrt(sigma_sq) * (theta0 - theta1)
pot.norm <- pnorm(kn + delta, lower.tail=FALSE)

```

Para el test del signo, consideremos las variables  $Y_i = \mathbb{1}\{X_i > 0\}$ , y el estadístico  $S = \sum_{i=1}^n Y_i$ . Bajo  $H_0$ ,  $X_i \sim F \in \Omega_s$  sabemos que  $X_i$  es simétrica alrededor del 0, así que,

$$Y_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}\left(\frac{1}{2}\right), \quad S \sim \text{Binomial}\left(n, \frac{1}{2}\right)$$

Podemos escribir un test

$$\phi_s(\mathbf{X}) = \mathbb{1}\{S(\mathbf{X}) \geq k^*\}$$

$$\mathbb{E}_0(\phi_s) = \mathbb{E}_0(\mathbb{1}\{S(\mathbf{X}) \geq k^*\}) = \Pr_0(S(\mathbf{X}) \geq k^*) = \alpha^* \leq \alpha$$

Para la elección de  $k^*$ , buscamos el *mínimo*  $k^* : \Pr_0(S \geq k^*) \leq \alpha$ . Cuando  $n = 12$  y  $\alpha = 0.05$ , resulta que podemos tomar

```

k.sgn <- which.max(pbinom(0:n, n, 1/2, lower.tail=FALSE) <= alfa)
alfa.sgn <- sum(dbinom(k.sgn:n, n, 1/2))
Tsigno <- function(x, theta0) { setNames(sum(x > theta0), "S") }
boot.Signo <- vector(mode = "numeric", length = length(x))
for (i in seq.int(m)) {
  Y <- rnorm(n, mean=theta1, sd=sqrt(sigma_sq))
  boot.Signo[i] <- Tsigno(Y, theta0)
}
pot.boot.sgn <- mean(boot.Signo >= k.sgn)

```

Resulta entonces que  $k_s^* = 10$ ,  $\alpha_s^* = 0.01929\dots$  y  $\widehat{\pi_{\phi_s}}(1) \approx 0.7068$ . En este caso, la potencia quedó demasiado baja, pues bajar  $k_s^* = 9$  subía  $\alpha_s^* \approx 0.73$ ; en ese caso la potencia pasaba a ser  $\approx 0.89$ .

Finalmente, si quisiéramos construir un «test  $t$ », usamos la fórmula que ya conocemos de memoria. Si  $t_{n,\alpha}$  es el cuantil de una  $t$  de Student que acumula *a derecha* probabilidad de  $\alpha$ , tenemos el estadístico  $W$  que distribuye como  $t_{n-1}$ , con

$$W = \sqrt{n} \frac{\bar{X} - \theta_0}{s(\mathbf{X})} \sim t_{n-1}$$

$$\phi_t(\mathbf{X}) = \mathbb{1}\{W(\mathbf{X}) \geq t_{n-1,\alpha}\}$$

$$\mathbb{E}_0(\phi_s) = \mathbb{E}_0(\mathbb{1}\{W > t_{n-1,\alpha}\}) = \Pr_0(W \geq t_{n-1,\alpha}) = \alpha$$

Ahora bien, ¿cómo calcular la potencia? Si  $\Psi_k$  es la función de distribución de una  $t_k$ , uno estaría tentado de seguir la lógica de  $\phi_n$  y escribir

$$\pi_{\phi_t}(\theta_1) = \Psi_k\left(t_{n-1,\alpha} + \sqrt{n} \frac{\theta_0 - \theta_1}{s(\mathbf{X})}\right)$$

Lamentablemente,  $s(\mathbf{X})$  es una variable aleatoria, y por ende  $\Psi_k(\cdot)$  también. En su lugar, se puede usar la distribución  $t$  de Student no-central. Sean

$$A \sim \text{Normal}(0, 1), \quad B \sim X_b^2, \quad A \perp B, \quad b \in \mathbb{N}, \quad \delta \in \mathbb{R}$$

entonces  $V = \frac{A+\delta}{\sqrt{B/b}}$  tiene distribución  $t$  no-central con parámetro de no-centralidad<sup>24</sup>  $\delta$ , y la notamos  $V \sim t_{b,\delta}$ . Sea entonces  $\Psi_{n,\mu}$  la distribución de una  $t_{n,\mu}$ , donde por convención  $\Psi_{n,0} = \Psi_n$ . Operando un poco con  $W$ , se puede reescribir como:

$$W = \sqrt{n} \frac{\bar{X} - \theta_0}{s(\mathbf{X})} = \left[ \left( \sqrt{n} \frac{\bar{X} - \theta_1}{\sigma} + \sqrt{n} \frac{\theta_1 - \theta_0}{\sigma} \right) \right] / \sqrt{\frac{(n-1)s^2}{\sigma^2} / (n-1)} = \frac{A + \delta}{\sqrt{B/b}}$$

$$\text{con } A = \sqrt{n} \frac{\bar{X} - \theta_1}{\sigma} \sim \text{Normal}(0, 1), \quad B = \frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2, \quad A \perp B, \quad \delta = \sqrt{n} \frac{\theta_1 - \theta_0}{\sigma}$$

Luego, bajo  $H_1$ ,  $W \sim t_{n-1,\delta}$  y podemos calcular la potencia según:

$$\pi_{\phi_t}(\theta_1) = \Pr_1(W \geq t_{n-1,\alpha}) = 1 - \Psi_{n-1,\delta}(t_{n-1,\alpha}) \approx 1 - \Psi_{11,-3.464}(1.7958) \approx 0.9447$$

```
# A mano
k.t <- qt(alfa, df=n-1, ncp=0, lower.tail=FALSE)
ncp <- sqrt(n) * (thetal - theta0) / sqrt(sigma_sq)
pot.t <- pt(k.t, ncp=ncp, df=n-1, lower.tail=FALSE)
# 0 usando R
R.pot.t <- power.t.test(
  n=n,
  delta = thetal,
  sd=sqrt(sigma_sq),
  sig.level = alfa,
  type = "one.sample",
  alternative = "one.sided"
)
stopifnot(isTRUE(all.equal(pot.t, R.pot.t$power)))
```

Finalmente, nos quedan los tests ordenados ascendentemente según sus potencias como:

$$\begin{aligned} \text{Signo} &< \text{Wilcoxon} < \text{t-Student} < \text{Normal} \\ 0.7068 &< 0.9324 < 0.9447 < 0.9656 \end{aligned}$$

Ya mencionamos que la potencia del test del signo quedó bastante baja por el  $\alpha_s^* \approx 0.02$ . Dicho esto, la jerarquía de potencias es la esperada, pero - tal vez no tan - sorpresivamente, el test de Wilcoxon tiene una potencia comparable a la de «t-Student» y «Normal», con hipótesis muchísimo más laxas. ■

<sup>24</sup>«ncp» o *non-centrality parameter* por sus siglas en inglés