

Generalización

Sean X_1, \dots, X_n v.a. i.i.d. con distribución $F(x, \theta)$ y $g : \mathbb{R} \rightarrow \mathbb{R}$ una función con esperanza finita.

El método generalizado de los momentos estima a θ como la solución de

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = \mathbb{E}_{\hat{\theta}}(g(X_1))$$

Generalización

Sean X_1, \dots, X_n v.a. i.i.d. con distribución $F(x, \theta)$ y $g : \mathbb{R} \rightarrow \mathbb{R}$ una función con esperanza finita.

El método generalizado de los momentos estima a θ como la solución de

$$\frac{1}{n} \sum_{i=1}^n g(X_i) = \mathbb{E}_{\hat{\theta}}(g(X_1))$$

Resolvamos el siguiente ejemplo:

Sea X_1, \dots, X_n una muestra aleatoria de una población con densidad de la forma

$$f(x, \theta) = (1 - \theta)\mathbb{I}_{(-\frac{1}{2}, 0)}(x) + (1 + \theta)\mathbb{I}_{(0, \frac{1}{2})}(x), \quad -1 < \theta < 1$$

Hallar un estimador de momentos para $q(\theta) = \mathbb{P}_{\theta}(X > 0)$.

Estimadores de Máxima Verosimilitud

¿Qué es la verosimilitud?

- Antes de realizar el *experimento* el **resultado** es **desconocido**.
- Las probabilidades nos permiten predecir un resultado **desconocido** a partir de parámetros **conocidos**: por ejemplo

$$P(\text{resultado}|\theta) \text{ por ej. caso Bernoulli} \quad \stackrel{=}{=} \quad P(x|\theta) = \theta^x(1 - \theta)^{(1-x)}$$

En Estadística se invierte el paradigma:

- Al realizar el experimento el **resultado** se hace **conocido**: **dato**.
- Nos interesa cuán **verosímil** es que un determinado parámetro haya generado el dato.

Ejemplo

El Método Máxima Verosimilitud es uno de los procedimientos más populares.

Sea X una variable aleatoria que corresponde al valor que toma un tetraedro con caras numeradas del 1 al 4 al ser arrojado de acuerdo con la ley \mathbb{P}_θ . Hay dos posibilidades: $\theta = \theta_0$ o θ_1 y los valores de $\mathbb{P}_{\theta_j}(\{i\})$ están dados por la siguiente tabla:

	$x = 1$	$x = 2$	$x = 3$	$x = 4$
$\theta = \theta_0$	0.7	0.1	0.1	0.1
$\theta = \theta_1$	0.1	0.3	0.3	0.3

Si $X = 1$ es observado, es más probable que provenga de P_{θ_0} , dado que $P_{\theta_0}(\{1\})$ es mucho mayor que $P_{\theta_1}(\{1\})$.

Luego, estimaríamos a θ por θ_0 .

Ejemplo

Por otro lado, si $X = 2$ o 3 o 4 , es más probable que provenga de P_{θ_1} , aunque en este caso la diferencia entre las probabilidades no es tan grande como cuando $X = 1$.

Esto sugiere como estimador de θ :

$$T(X) = \begin{cases} \theta_0 & X = 1 \\ \theta_1 & X \neq 1. \end{cases}$$

Ejemplo

Por otro lado, si $X = 2$ o 3 o 4 , es más probable que provenga de P_{θ_1} , aunque en este caso la diferencia entre las probabilidades no es tan grande como cuando $X = 1$.

Esto sugiere como estimador de θ :

$$T(X) = \begin{cases} \theta_0 & X = 1 \\ \theta_1 & X \neq 1. \end{cases}$$

Esta idea puede extenderse fácilmente al caso en que \mathbb{P}_θ es una distribución discreta y $\theta \in \Theta \subset \mathbb{R}^k$.

Si $X = x$ es observada, θ_1 es más probable que θ_0 si y sólo si $\mathbb{P}_{\theta_1}(\{x\}) > \mathbb{P}_{\theta_0}(\{x\})$.

Podemos estimar θ por el valor $\hat{\theta}$ que maximiza $\mathbb{P}_\theta(\{x\})$ sobre $\theta \in \Theta$, si tal $\hat{\theta}$ existe.

Esto se extiende en forma directa al caso de X continua.

Estimador de Máxima Verosimilitud: Caso discreto

- Modelo: $\mathcal{F} = \{p(\cdot, \theta), \theta \in \Theta\}$.
- $\mathbf{x} = x_1, \dots, x_n$ realización de X_1, \dots, X_n i.i.d. donde $X_i \sim p(\cdot, \theta)$.
- Función de verosimilitud asociada a $\mathbf{x} = x_1, \dots, x_n$:

$$L(\cdot, \mathbf{x}) : \Theta \rightarrow \mathbb{R}$$

$$L(\theta, \mathbf{x}) = \mathbb{P}_\theta(X_1 = x_1, \dots, X_n = x_n), X_i \sim p(\cdot, \theta)$$

$$L(\theta, \mathbf{x}) = \prod_{i=1}^n p(x_i, \theta),$$

Estimador de Máxima Verosimilitud: Caso discreto

- Modelo: $\mathcal{F} = \{p(\cdot, \theta), \theta \in \Theta\}$.
- $\mathbf{x} = x_1, \dots, x_n$ realización de X_1, \dots, X_n i.i.d. donde $X_i \sim p(\cdot, \theta)$.
- Función de verosimilitud asociada a $\mathbf{x} = x_1, \dots, x_n$:

$$L(\cdot, \mathbf{x}) : \Theta \rightarrow \mathbb{R}$$

$$L(\theta, \mathbf{x}) = \mathbb{P}_\theta(X_1 = x_1, \dots, X_n = x_n), X_i \sim p(\cdot, \theta)$$

$$L(\theta, \mathbf{x}) = \prod_{i=1}^n p(x_i, \theta),$$

- Propuesta de máxima verosimilitud: $\hat{\theta}$ es el EMV si

$$L(\hat{\theta}(\mathbf{X}), \mathbf{X}) = \operatorname{argmax}_{\theta \in \Theta} L(\theta, \mathbf{X}).$$

o sea

$$L(\hat{\theta}(\mathbf{X}), \mathbf{X}) \geq L(\theta, \mathbf{X})$$

Ejemplo: Bernoulli

- $(X_i)_{i \geq 1}$ i.i.d., $X_i \sim \mathcal{B}(1, \theta)$, $\theta \in [0, 1]$
- $L(\theta; \mathbf{x})$: probabilidad de observar $\mathbf{x} = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ en n lanzamientos cuando la probabilidad de cara es θ . Notemos que $x_i = 1$ o 0 .
- $(X_i)_{i \geq 1}$ i.i.d., $X_i \sim \mathcal{B}(1, \theta)$, $p(x, \theta) = \theta^x(1 - \theta)^{1-x}$

$$\begin{aligned} L(\theta; \mathbf{x}) &= \prod_{i=1}^n p(x_i, \theta) \\ &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \\ &= \theta^{n\bar{x}} (1 - \theta)^{n - n\bar{x}} = \theta^{n\bar{x}} (1 - \theta)^{n(1-\bar{x})} \end{aligned}$$

Ejemplo: Bernoulli

- $(X_i)_{i \geq 1}$ i.i.d., $X_i \sim \mathcal{B}(1, \theta)$, $\theta \in [0, 1]$
- $L(\theta; \mathbf{x})$: probabilidad de observar $\mathbf{x} = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ en n lanzamientos cuando la probabilidad de cara es θ . Notemos que $x_i = 1$ o 0 .

- $(X_i)_{i \geq 1}$ i.i.d., $X_i \sim \mathcal{B}(1, \theta)$, $p(x, \theta) = \theta^x(1 - \theta)^{1-x}$

$$\begin{aligned} L(\theta; \mathbf{x}) &= \prod_{i=1}^n p(x_i, \theta) \\ &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \\ &= \theta^{n\bar{x}} (1 - \theta)^{n - n\bar{x}} = \theta^{n\bar{x}} (1 - \theta)^{n(1-\bar{x})} \end{aligned}$$

- Maximizar $L(\theta; \mathbf{x})$ equivale a maximizar $\ell(\theta; \mathbf{x}) = \log \mathbf{L}(\theta; \mathbf{x})$ ya que log es estrictamente creciente.

Función de Verosimilitud basada en \mathbf{x}

Caso Bernoulli

- Maximizar $L(\theta; \mathbf{x})$ equivale a maximizar $\ell(\theta; \mathbf{x}) = \log \mathbf{L}(\theta; \mathbf{x})$

$$\ell(\theta; \mathbf{x}) = n\bar{x} \log(\theta) + n(1 - \bar{x}) \log(1 - \theta)$$

- Derivemos e igualemus a 0:

$$\frac{\partial \ell(\theta; \mathbf{x})}{\partial \theta} = \frac{n\bar{x}}{\theta} - \frac{n(1 - \bar{x})}{1 - \theta} = 0$$

- Cuando $0 < \bar{x} < 1$, hay un único punto crítico \bar{x}
- La derivada segunda es:

$$\frac{\partial^2 \ell(\theta; \mathbf{x})}{\partial^2 \theta} = -\frac{n\bar{x}}{\theta^2} - \frac{n(1 - \bar{x})}{(1 - \theta)^2}$$

que es siempre negativa.

Estimador de Máxima Verosimilitud: Caso discreto

Caso Bernoulli

- $L(\theta, \mathbf{x})$ tiende a 0 cuando θ tiende a 0 o a 1 (la frontera del espacio paramétrico): \bar{x} es el único máximo de θ .
- Cuando $\bar{x} = 0$, $L(\theta) = (1 - \theta)^n$ es estrictamente decreciente como función de θ y por lo tanto 0 es el único máximo. Análogamente si $\bar{x} = 1$.
- Combinando todo esto, cada vez que se observan los datos x_1, \dots, x_n tenemos que \bar{x} maximiza, el estimador de máxima verosimilitud es

$$\hat{\theta} = \bar{X}$$

Observación: si el espacio paramétrico fuera $\Theta = (0, 1)$, cuando $\bar{x} = 0$ o 1, tenemos que el máximo no se alcanza en Θ , sin embargo el supremo en $(0, 1)$ es 1, con lo cual el EMV toma un valor fuera de $(0, 1)$, que no sería un valor razonable. Sin embargo, a medida que n crece la probabilidad de que esto ocurra tiende a 0.

Estimador de Máxima Verosimilitud

Algunas observaciones

- Algunos textos trabajan con la clausura del espacio paramétrico $\overline{\Theta}$ en lugar de Θ . Esto es porque el máximo de $L(\theta)$ podría no existir en Θ .
- Cuando el espacio paramétrico consiste en un conjunto finito de puntos, entonces $\overline{\Theta} = \Theta$ y el MLE puede obtenerse haciendo un número finito de comparaciones.
- Como hemos visto, en casos regulares, podemos trabajar con $\ell(\theta)$ en lugar de la verosimilitud y los candidatos a EMV se obtienen resolviendo

$$\frac{\partial \ell(\theta; \mathbf{x})}{\partial \theta} = 0$$

Una raíz de esto podría ser un mínimo local o global, idem máximo o un punto estacionario. También los máximos podrían ocurrir en la frontera de Θ o cuando $\|\theta\| \rightarrow \infty$.

- En algunos casos $\ell(\theta)$ no es diferenciable.
- Un MLE podría no existir o podría haber más de uno.
- Un MLE puede no tener una forma explícita.

Estimador de Máxima Verosimilitud: Caso continuo

- Modelo: $\mathcal{F} = \{f(\cdot, \theta), \theta \in \Theta\}$, con $f(\cdot, \theta)$ función de densidad.
- $\mathbf{x} = x_1, \dots, x_n$ realización correspondiente a X_1, \dots, X_n con $X_i \sim f(\cdot, \theta)$.
- Función de verosimilitud: $L(\cdot; \mathbf{x}) : \Theta \rightarrow \mathbb{R}$

$$L(\theta; \mathbf{x}) = f_{X_1, \dots, X_n}(x_1, \dots, x_n), X_i \sim f(\cdot, \theta).$$

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i, \theta),$$

- Propuesta de máxima verosimilitud: $\hat{\theta}$ es el EMV si

$$L(\hat{\theta}(\mathbf{X}), \mathbf{X}) = \operatorname{argmax}_{\theta \in \Theta} L(\theta, \mathbf{X}).$$

o sea

$$L(\hat{\theta}(\mathbf{X}), \mathbf{X}) \geq L(\theta, \mathbf{X})$$

Ejemplo $\mathcal{E}(\lambda)$

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{E}(\lambda), \lambda > 0$. $f(x, \lambda) = \lambda e^{-x\lambda} \mathcal{I}_{[0, \infty)}(x)$.

$$L(\lambda; \mathbf{x}) = \prod_{i=1}^n f(x_i, \lambda) = \prod_{i=1}^n \lambda e^{-x_i \lambda} \mathcal{I}_{[0, \infty)}(x_i)$$

- si $x_i \geq 0 \forall i$

$$L(\lambda; \mathbf{x}) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

- Si consideramos el $\log L$, resulta

$$\ell(\lambda; \mathbf{x}) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

- Derivando e igualando a 0 queda

$$\frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \Rightarrow \text{punto crítico es } 1/\bar{x}$$

- $\Rightarrow \hat{\lambda} = 1/\bar{X}_n$

Ejemplo $\mathcal{N}(\mu, \sigma^2)$

$$X_1, \dots, X_n \text{ v.a. i.i.d. } f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Ejemplo $\mathcal{N}(\mu, \sigma^2)$

$$X_1, \dots, X_n \text{ v.a. i.i.d. } f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

Ejemplo $\mathcal{N}(\mu, \sigma^2)$

$$X_1, \dots, X_n \text{ v.a. i.i.d. } f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

- Tomando logaritmo y resolviendo las ecuaciones

$$\frac{\partial \ell(\mu, \sigma^2; \mathbf{x})}{\partial \mu} = 0 \quad \text{y} \quad \frac{\partial \ell(\mu, \sigma^2; \mathbf{x})}{\partial \sigma^2} = 0$$

se obtiene que los EMV de μ y σ^2 son

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}$$

Consideremos la matriz de derivadas segundas H

Comprobar que

$$\frac{\partial^2}{\partial \mu^2} \ell(\mu, \sigma^2) = -\frac{n}{\sigma^2}, \quad \frac{\partial^2}{\partial (\sigma^2)^2} \ell(\mu, \sigma^2) = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n (X_i - \mu)^2$$

$$\frac{\partial^2}{\partial \mu \partial \sigma^2} \ell(\mu, \sigma^2) = \frac{\partial^2}{\partial \sigma^2 \partial \mu} \ell(\mu, \sigma^2) = -\frac{\sum_{i=1}^n (X_i - \mu)}{\sigma^4} = \frac{n\mu - n\bar{X}}{\sigma^4}.$$

Evaluando a H en $(\hat{\mu}, \hat{\sigma}^2)$ resulta:

$$\begin{aligned}\frac{\partial^2}{\partial \mu^2} \ell(\mu, \sigma^2) \Big|_{(\hat{\mu}, \hat{\sigma}^2)} &= -\frac{n}{\hat{\sigma}^2}, & \frac{\partial^2}{\partial (\sigma^2)^2} \ell(\mu, \sigma^2) \Big|_{(\hat{\mu}, \hat{\sigma}^2)} &= \frac{n}{2\hat{\sigma}^4} - \frac{n\hat{\sigma}^2}{\hat{\sigma}^6} = -\frac{n}{2\hat{\sigma}^4} \\ \frac{\partial^2}{\partial \mu \partial \sigma^2} \ell(\mu, \sigma^2) \Big|_{(\hat{\mu}, \hat{\sigma}^2)} &= \frac{\partial^2}{\partial \sigma^2 \partial \mu} \ell(\mu, \sigma^2) \Big|_{(\hat{\mu}, \hat{\sigma}^2)} = \frac{n\hat{\mu} - n\hat{\mu}}{\hat{\sigma}^4} = 0.\end{aligned}$$

que resulta una matriz diagonal y es fácil comprobar que es definida negativa pues $\hat{\sigma}^2 > 0$.

Invarianza de los E.M.V.

¿Cuál sería el EMV de σ en el caso anterior?

Invarianza de los E.M.V.

¿Cuál sería el EMV de σ en el caso anterior?

Sea $\lambda = h(\theta) : \Theta \rightarrow \Lambda$ una función *biyectiva*.

Luego, la densidad $f(\mathbf{x}, \theta)$ se puede expresar en función de λ ya que $\theta = h^{-1}(\lambda)$.

Notamos la densidad de \mathbf{X} como función de λ por $f^*(\mathbf{x}, \lambda)$. Se tiene

$$f^*(\mathbf{x}, \lambda) = f(\mathbf{x}, h^{-1}(\lambda))$$

Entonces,

$$L^*(\mathbf{x}, \lambda) = L(\mathbf{x}, h^{-1}(\lambda))$$

Luego, se definen los E.M.V. $\hat{\theta}$ y $\hat{\lambda}$ por

$$L(\mathbf{x}, \hat{\theta}) = \max_{\theta \in \Theta} L(\mathbf{x}, \theta)$$

y

$$L^*(\mathbf{x}, \hat{\lambda}) = \max_{\lambda \in \Lambda} L^*(\mathbf{x}, \lambda)$$

Propiedad de Invarianza del EMV

Teorema: Si $\hat{\theta}$ es E.M.V. de θ , entonces $\hat{\lambda} = h(\hat{\theta})$ es E.M.V. de λ .

En efecto:

$$L(\mathbf{x}, \hat{\theta}) = \max_{\theta \in \Theta} L(\mathbf{x}, \theta) \stackrel{(1)}{=} \max_{\lambda \in \Lambda} L(\mathbf{x}, h^{-1}(\lambda)) \stackrel{(2)}{=} \max_{\lambda \in \Lambda} L^*(\mathbf{x}, \lambda) = L^*(\mathbf{x}, \hat{\lambda})$$

ya que

- (1): coinciden los conjuntos $\{\theta \in \Theta\}$ y $\{h^{-1}(\lambda) : \lambda \in \Lambda\}$
- (2): por definición de L^* .

Finalmente, como h es biyectiva $\hat{\lambda} = h(\hat{\theta})$.

Propiedad de Invarianza del EMV

Teorema: Si $\hat{\theta}$ es E.M.V. de θ , entonces $\hat{\lambda} = h(\hat{\theta})$ es E.M.V. de λ .

En efecto:

$$L(\mathbf{x}, \hat{\theta}) = \max_{\theta \in \Theta} L(\mathbf{x}, \theta) \stackrel{(1)}{=} \max_{\lambda \in \Lambda} L(\mathbf{x}, h^{-1}(\lambda)) \stackrel{(2)}{=} \max_{\lambda \in \Lambda} L^*(\mathbf{x}, \lambda) = L^*(\mathbf{x}, \hat{\lambda})$$

ya que

- (1): coinciden los conjuntos $\{\theta \in \Theta\}$ y $\{h^{-1}(\lambda) : \lambda \in \Lambda\}$
- (2): por definición de L^* .

Finalmente, como h es biyectiva $\hat{\lambda} = h(\hat{\theta})$.

Ejemplo:

si X_1, \dots, X_n son i.i.d. $X_i \sim N(\mu, 1)$, tenemos que

$$\mathbb{P}[X_1 \leq x] = \mathbb{P}[X_1 - \mu \leq x - \mu] = \Phi(x - \mu),$$

luego como ϕ es estrictamente creciente y \bar{X} es el EMV de μ , el estimador de máxima versosimilitud de esta probabilidad es

$$\Phi(x - \bar{X})$$

EMV

A veces las cosas se complican un poco....

- ya sea porque $L(\theta; \mathbf{x})$ no es derivable como función de θ :
Caso X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{U}[0, \theta]$: familia no regular.
Notar que la indicadora de la densidad depende del parámetro.

EMV de θ : $\hat{\theta} = \max(X_1, \dots, X_n)$

EMV

A veces las cosas se complican un poco....

- ya sea porque $L(\theta; \mathbf{x})$ no es derivable como función de θ :
Caso X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{U}[0, \theta]$: familia no regular.
Notar que la indicadora de la densidad depende del parámetro.

EMV de θ : $\hat{\theta} = \max(X_1, \dots, X_n)$

- o porque el óptimo no es tan fácil de hallar.
- Tarea: explorar caso $\Gamma(\alpha, \lambda)$

Ejemplo $U[0, \theta]$

$X_1 \dots X_n$, i.i.d., $X_i \sim \mathcal{U}[0, \theta]$. $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x)$.

$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathcal{I}_{[0, \theta]}(x_i)$$

Ejemplo $U[0, \theta]$

$X_1 \dots X_n$, i.i.d., $X_i \sim \mathcal{U}[0, \theta]$. $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x)$.

$$\begin{aligned} f(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathcal{I}_{[0, \theta]}(x_i) \\ &= \begin{cases} \frac{1}{\theta^n} & \text{si } 0 \leq x_i \leq \theta \text{ para todo } i \\ 0 & \text{otro caso} \end{cases} \end{aligned}$$

Ejemplo $U[0, \theta]$

$$X_1 \dots X_n, \text{i.i.d.}, X_i \sim \mathcal{U}[0, \theta]. \quad f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x).$$

$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathcal{I}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathcal{I}_{[0, \theta]}(x_i)$$

$$= \begin{cases} \frac{1}{\theta^n} & \text{si } 0 \leq x_i \leq \theta \text{ para todo } i \\ 0 & \text{otro caso} \end{cases}$$


$$= \begin{cases} \frac{1}{\theta^n} & \text{si } \theta \geq \max(x_i) \\ 0 & \text{otro caso} \end{cases}$$

Estimador de Máxima Verosimilitud: Distribución Uniforme

(¡Gracias Marina V.!!)

Gráfico de la función de verosimilitud, $f(\mathbf{x}, \theta)$ correspondiente a $n = 8$ observaciones tales que

$$\max_{1 \leq i \leq n} (x_i) = 5$$



Estimador de Máxima Verosimilitud: Distribución Uniforme

El E.M.V. de θ es

$$\hat{\theta}_n = \max_{1 \leq i \leq n} (X_i)$$