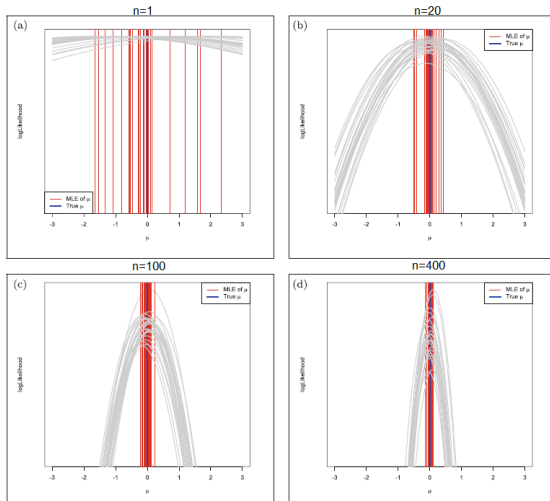


Estimadores: Propiedades

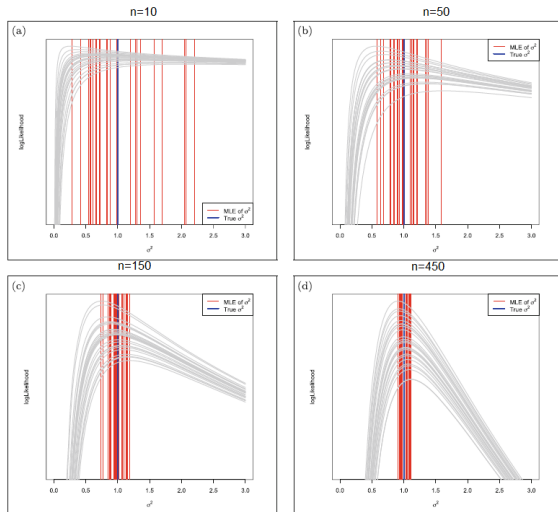
Fluctuación; log-Verosimilitud y su máximo (EMV) $X_i \sim N(\mu, 1)$

Panaretos, V. M. 2016. *Statistics for Mathematicians: A Rigorous First Course*, Birkhäuser, Springer.



25 replications

Fluctuación: log-Verosimilitud y su máximo (EMV) $X_i \sim N(0, \sigma^2)$



25 replicaciones

- En ambos casos se observa cómo las funciones de log-verosimilitud se vuelven gradualmente más curvas a medida que n aumenta, por lo que su máximo fluctúa cada vez menos de una repetición a otra.
- También se observa que los máximos tienden a concentrarse alrededor del verdadero valor del parámetro a medida que n aumenta.

Ejemplo: $\mathcal{U}[0, \theta]$

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{U}[0, \theta]$

- Estimador de Momentos: $\hat{\theta}_n = 2\bar{X}_n$
- Estimador de Máxima Verosimilitud: $\tilde{\theta}_n = \max_{1 \leq i \leq n} (X_i)$

Visitemos la app de shiny

¡Gracias Mariela!!!

https://glmconr2.shinyapps.io/estimadores_uniforme/

Visitemos la app de shiny

¡Gracias Mariela!!!

https://glmconr2.shinyapps.io/estimadores_uniforme/

- $\hat{\theta}_n$ y $\tilde{\theta}_n$ son variables aleatorias: tienen una distribución



- En la práctica tenemos una sola estimación!!
- Veamos un ejemplo.

Ejemplo: Estimamos una proporción

Queremos estimar a p , la proporción de ciudadanos de Argentina que está a favor de las vacunas. Para ello, elegiremos n ciudadanos al azar y se les preguntará si están a favor de las vacunas o no. ¿Cómo estimamos a p ?

Ejemplo: Estimamos una proporción

Queremos estimar a p , la proporción de ciudadanos de Argentina que está a favor de las vacunas. Para ello, elegiremos n ciudadanos al azar y se les preguntará si están a favor de las vacunas o no. ¿Cómo estimamos a p ?

$$X_i = \begin{cases} 1 & \text{si la } i \text{ ésimo encuestado dice que sí} \\ 0 & \text{si no} \end{cases}$$

- X_1, \dots, X_n son variables aleatorias i.i.d. con distribución $B(1, p)$, siendo p la verdadera proporción que queremos estimar.
- Un estimador puntual (EMM o EMV) de p es $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- Una vez realizado el experimento con $n = 1000$, observamos que hay 853 personas a favor. Obtenemos una **estimación** para p :
 $\hat{p}_{n \text{ obs}} = 0.853$.
- ¿Por qué tomamos $n = 1000$? ¿Sería más conveniente tomar $n = 2000$? ¿Cómo se aprecia si es mejor una elección que la otra?

Criterios de bondad de un estimador: Sesgo

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, $\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y supongamos que queremos estimar $q(\theta)$, una función real del parámetro de F

Un estimador de $q(\theta)$, $T_n = T(\mathbf{X}_n)$, se dice **insesgado** para $q(\theta)$ si

$$\mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Caso contrario, decimos que es **sesgado**. Un estimador de $q(\theta)$, T_n , se dice **asintóticamente insesgado** para $q(\theta)$ si

$$\lim_{n \rightarrow \infty} \mathbb{E}_\theta(T_n) = q(\theta) \text{ para todo } \theta \in \Theta.$$

Llamamos **sesgo** de un estimador T_n de $q(\theta)$ a

$$\mathbb{B}_\theta(T_n) = \mathbb{E}_\theta(T_n) - q(\theta).$$

Ejemplo: Volviendo a las vacunas...

X_1, \dots, X_n son variables aleatorias i.i.d. $X_i \sim B(1, p)$, siendo p la verdadera proporción que queremos estimar. Tenemos que

$$\mathbb{E}_p(X_1) = p.$$

- $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$

- $\mathbb{E}_p(\hat{p}_n) = \mathbb{E}_p(\bar{X}_n) = \frac{1}{n} \mathbb{E}_p\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_p(X_1) = p$

- En este caso, resulta $\mathbb{E}_p(\hat{p}_n) = p$

Ejemplo: Caso general - F con media y varianza

Sea $\mathbf{X}_n = (X_1 \dots X_n)$ una muestra aleatoria de una distribución $F \in \mathcal{F}$, y supongamos que queremos estimar $q(F)$.

Ejemplos: $q_1(F) = \mathbb{E}_F(X_1)$ $q_2(F) = \mathbb{V}_F(X_1)$.

- ¿Cómo estimamos a $q_1(F)$ y $q_2(F)$?
- Vimos que los estimadores de momentos son:

$$\begin{aligned}\hat{q}_1(F) &= \bar{X}_n \\ \hat{q}_2(F) &= \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n} = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\end{aligned}$$

- ¿Son insesgados?

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

→ insesgado!

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

→ insesgado!

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

→ insesgado!

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} E_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

→ insesgado!

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} \mathbb{E}_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \left\{ \mathbb{V}_F(\bar{X}) + \mathbb{E}_F(\bar{X})^2 \right\}$$

Ejemplo: Calculemos el sesgo de cada uno

- $E_F(\bar{X}_n) = \frac{1}{n} \mathbb{E}_F\left(\sum_{i=1}^n X_i\right) = \frac{n}{n} \mathbb{E}_F(X_1) = \mathbb{E}_F(X_1) = q_1(F)$

→ insesgado!

- $\mathbb{E}_F\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right)$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}_F(X_i^2) - \mathbb{E}_F(\bar{X}^2) = \frac{n}{n} \mathbb{E}_F(X_1^2) - \mathbb{E}_F(\bar{X}^2)$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \left\{ \mathbb{V}_F(\bar{X}) + \mathbb{E}_F(\bar{X})^2 \right\}$$

$$= \mathbb{V}_F(X_1) + \mathbb{E}_F(X_1)^2 - \frac{\mathbb{V}_F(X_1)}{n} - \mathbb{E}_F(X_1)^2 = \frac{n-1}{n} \mathbb{V}_F(X_1)$$

Ejemplo: Calculemos el sesgo de cada uno

- El sesgo es

$$\begin{aligned}\mathbb{B}_F \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right) &= \frac{n-1}{n} \mathbb{V}_F(X_1) - \mathbb{V}_F(X_1) \\ &= -\mathbb{V}_F(X_1)/n < 0\end{aligned}$$

→ sesgo: $-\frac{1}{n} \mathbb{V}_F(X_1)$ subestima!

- El sesgo puede corregirse

$$\frac{n}{n-1} \hat{q}_2(F) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = S^2$$

que hemos llamado **varianza muestral**.

Ejemplo: Caso Normal

Supongamos que $\mathbf{X}_n = (X_1 \dots X_n)$ i.i.d. $X_i \sim N(\mu, \sigma^2)$, y que queremos estimar a μ y σ^2 .

Como sabemos $q_1(F) = \mathbb{E}_F(X_1) = \mu$ y $q_2(F) = \mathbb{V}_F(X_1) = \sigma^2$.

Por lo que hemos visto, \bar{X}_n y $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ son estimadores insesgados de μ y σ^2 , respectivamente.

Error cuadrático medio

$\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$,

$\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. El error de estimación es:

$$T_n - q(\theta)$$

Error cuadrático medio

$\mathbf{X}_n = (X_1 \dots X_n)$ una m. a. de una distribución $F \in \mathcal{F}$,

$\mathcal{F} = \{F(\cdot, \theta), \theta \in \Theta\}$ y queremos estimar $q(\theta)$.

Sea $T_n = T(\mathbf{X}_n)$ un estimador de $q(\theta)$. El error de estimación es:

$$T_n - q(\theta) \quad \text{es una v.a.}$$

Una noción del error cometido está dada por el **Error Cuadrático Medio**

$$ECM_{\theta}(T_n) = \mathbb{E}_{\theta} \left((T_n - q(\theta))^2 \right)$$

El **Error Cuadrático Medio** da un criterio para determinar si un estimador T_n de $q(\theta)$ es mejor que otro W_n , pues basta verificar si

$$ECM_{\theta}(T_n) \leq ECM_{\theta}(W_n) \quad \forall \theta \in \Theta$$

Compromiso sesgo-varianza

Teorema

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

Compromiso sesgo-varianza

Teorema

$$ECM_{\theta}(T_n) = \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2$$

$$\begin{aligned} ECM_{\theta}(T_n) &= \mathbb{E}_{\theta} [(T_n - q(\theta))^2] \\ &= \mathbb{V}_{\theta} [(T_n - q(\theta))] + [\mathbb{E}_{\theta}(T_n - q(\theta))]^2 \\ &= \mathbb{V}_{\theta}(T_n) + [\mathbb{E}_{\theta}(T_n) - q(\theta)]^2 \\ &= \mathbb{V}_{\theta}(T_n) + (\mathbb{B}_{\theta}(T_n))^2, \text{ como queríamos demostrar.} \end{aligned}$$

ECM

Notemos que

- si el estimador T_n es insesgado, $ECM_\theta(T_n) = \mathbb{V}_\theta(T_n)$
- comparar el ECM de dos estimadores insesgados, se reduce a comparar sus varianzas.

Volvamos al ejemplo de estimar la proporción.

Recordemos que $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$ es insesgado como estimador de p .

Usando la independencia, tenemos que

$$\mathbb{V}(\hat{p}_n) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i) = \frac{\mathbb{V}(X_1)}{n} = \frac{p(1-p)}{n}.$$

¿Esto responde la pregunta que nos hicimos en el caso de las vacunas?

Volvamos al ejemplo de estimar la proporción.

Recordemos que $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n X_i$ es insesgado como estimador de p .

Usando la independencia, tenemos que

$$\mathbb{V}(\hat{p}_n) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i) = \frac{\mathbb{V}(X_1)}{n} = \frac{p(1-p)}{n}.$$

¿Esto responde la pregunta que nos hicimos en el caso de las vacunas?

Como \hat{p}_n es insesgado $ECM_p(\hat{p}_n) = \frac{p(1-p)}{n} \rightarrow 0$ si $n \rightarrow \infty$

ECM del EMM y EMV de θ para $U[0, \theta]$

(1) EMM: $\hat{\theta} = 2\bar{X}_n$. Para todo θ tenemos

$$E_{\theta}(\hat{\theta}) = 2E_{\theta}(\bar{X}_n) = 2 \frac{\theta}{2} = \theta$$

$$V_{\theta}(\hat{\theta}) = 4\mathbb{V}_{\theta}(\bar{X}_n) = 4 \frac{\theta^2}{12n} = \frac{\theta^2}{3n}$$

Por lo tanto

$$ECM_{\theta}(\hat{\theta}) = \mathbb{V}_{\theta}(\hat{\theta}) = \frac{\theta^2}{3n}$$

(2) EMV: $\tilde{\theta} = \max \{X_1, \dots, X_n\}$

Probarán que

$$ECM_{\theta}(\tilde{\theta}) = \frac{n}{(n+2)(n+1)^2} \theta^2 + \left(\frac{n}{n+1} \theta - \theta \right)^2 = \frac{2\theta^2}{(n+1)(n+2)}$$

En este caso, tenemos que $\forall n$

$$\frac{2\theta^2}{(n+1)(n+2)} \leq \frac{\theta^2}{3n}$$

$\hat{f}_h(x)$: estimador de Parzen

https://glmconr2.shinyapps.io/app_regre2/

1. Generá tu conjunto de datos: usá tu numero de libreta.
2. Realizá una estimación de la densidad usando el núcleo normal usando los valores de ventana $h = 0.25, 1, 4$. ¿Qué pasa a medida que h crece?
3. Pegá tus gráficos **acá**.

Estimadores de núcleos: Selección de ventana

En los gráficos anteriores se muestra que la elección de la ventana es crucial.

- Una ventana h pequeña dará un estimador muy rugoso, con muchos picos y difícil de interpretar
- una ventana h grande sobresuaviza al estimador de la densidad y enmascara estructuras de los datos.

$\hat{f}_h(x)$: estimador de Parzen

$$\hat{f}_h(x) = \frac{1}{2h n} \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h \leq X \leq x + h) = F(x + h) - F(x - h) = p_{x,h}$

$\hat{f}_h(x)$: estimador de Parzen

$$\hat{f}_h(x) = \frac{1}{2h} \frac{1}{n} \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h \leq X \leq x + h) = F(x + h) - F(x - h) = p_{x,h}$

Luego, usando las propiedades de esperanza y varianza:

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{2h} \\ \mathbb{V}\text{ar}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{4nh^2} - \frac{(F(x + h) - F(x - h))^2}{4nh^2}\end{aligned}$$

$\hat{f}_h(x)$: estimador de Parzen

$$\hat{f}_h(x) = \frac{1}{2h} \frac{1}{n} \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \quad \text{con} \quad \sum_{i=1}^n \mathcal{I}_{[x-h, x+h]}(X_i) \sim Bi(n, p)$$

donde $p = \mathbb{P}(x - h \leq X \leq x + h) = F(x + h) - F(x - h) = p_{x,h}$

Luego, usando las propiedades de esperanza y varianza:

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{2h} \\ \mathbb{V}\text{ar}[\hat{f}_h(x)] &= \frac{F(x + h) - F(x - h)}{4nh^2} - \frac{(F(x + h) - F(x - h))^2}{4nh^2}\end{aligned}$$

Si

- $h \rightarrow 0 \Rightarrow \mathbb{E}[\hat{f}_h(x)] \rightarrow f(x)$ y $\mathbb{V}\text{ar}[\hat{f}_h(x)] \approx \frac{f(x)}{2nh} - \frac{f(x)^2}{n} \rightarrow \infty$
- $nh \rightarrow \infty, n \rightarrow \infty, h \rightarrow 0$, entonces sesgo y varianza se reducen.

Sesgo y Varianza del estimador de Rosenblatt–Parzen

Supongamos que:

- la densidad f es de cuadrado integrable, dos veces continuamente diferenciable y su segunda derivada es de cuadrado integrable.
- el núcleo K es simétrico, es una densidad acotada, de cuadrado integrable y con segundo momento finito.
- $h = h_n \rightarrow 0$, $n \rightarrow \infty$ y $nh \rightarrow \infty$.

Luego,

$$\mathbb{B} \left(\hat{f}_h(x) \right) = \frac{1}{2} \mu_2(K) f''(x) h^2 + o(h^2)$$

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1})$$

Recomendamos:

Tesis de Licenciatura de Romina Cornistein: *Estimadores de Naradaya Watson aplicados a datos funcionales*

Disponible en:

<https://web.dm.uba.ar/index.php/509-tesis-de-licenciatura>

Sesgo del estimador de Rosenblatt–Parzen (Video 1)

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)$$

Sesgo del estimador de Rosenblatt–Parzen (Video 1)

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)$$

$$\mathbb{E}\left(\hat{f}_h(x)\right) = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)\right]$$

Sesgo del estimador de Rosenblatt–Parzen (Video 1)

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)$$

$$\begin{aligned}\mathbb{E}\left(\hat{f}_h(x)\right) &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)\right] \\ &= \frac{1}{n} \sum_{i=1}^n \frac{1}{h} \mathbb{E}\left[K\left(\frac{x - X_i}{h}\right)\right]\end{aligned}$$

Sesgo del estimador de Rosenblatt–Parzen (Video 1)

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)$$

$$\begin{aligned}\mathbb{E}\left(\hat{f}_h(x)\right) &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{x - X_i}{h}\right)\right] \\&= \frac{1}{n} \sum_{i=1}^n \frac{1}{h} \mathbb{E}\left[K\left(\frac{x - X_i}{h}\right)\right] \\&= \mathbb{E}\left[\frac{1}{h} K\left(\frac{x - X_1}{h}\right)\right] \\&= \int \frac{1}{h} K\left(\frac{x - s}{h}\right) f(s) ds\end{aligned}$$

Resolvemos la integral (Video 1)

$$\mathbb{E} \left(\hat{f}_h(x) \right) = \int \frac{1}{h} K \left(\frac{x-s}{h} \right) f(s) ds$$

Resolvemos la integral (Video 1)

$$\mathbb{E} \left(\hat{f}_h(x) \right) = \int \frac{1}{h} K \left(\frac{x-s}{h} \right) f(s) ds$$

hacemos el cambio de variables: $s = x - ht \rightarrow ds = -h dt$

$$= \int K(t) f(x - ht) dt$$

Resolvemos la integral (Video 1)

$$\mathbb{E} \left(\hat{f}_h(x) \right) = \int \frac{1}{h} K \left(\frac{x-s}{h} \right) f(s) ds$$

hacemos el cambio de variables: $s = x - ht \rightarrow ds = -h dt$

$$= \int K(t) f(x - ht) dt$$

ahora sumamos y restamos $f(x)$

$$= f(x) + \int K(t) f(x - ht) dt - \int f(x) K(t) dt$$

$$= f(x) + \int [f(x - ht) - f(x)] K(t) dt$$

Seguimos.... (Video 1)

Mediante un desarrollo de Taylor obtenemos

$$f(x - ht) = f(x) - f'(x)ht + \frac{f''(x)}{2}h^2t^2 + o(h^2t^2).$$

Luego,

$$\begin{aligned} & \int K(t)[f(x - ht) - f(x)] dt \\ &= \int K(t) \left\{ -f'(x)ht + \frac{f''(x)}{2}h^2t^2 + o(h^2t^2) \right\} dt \\ &= \frac{1}{2}\mu_2(K)f''(x)h^2 + o(h^2), \end{aligned}$$

siendo $\mu_2(K) = \int K(t)t^2 dt$ el segundo momento de K .

Varianza del estimador de Rosenblatt–Parzen (Video 1)

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \mathbb{V} \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{h} K \left(\frac{x - X_i}{h} \right) \right) = \frac{1}{n} \mathbb{V} \left(\frac{1}{h} K \left(\frac{x - X_1}{h} \right) \right) \text{ por qué?}$$

$$\begin{aligned} \swarrow \mathbb{V}(Z) &= \mathbb{E}(Z^2) - \mathbb{E}^2(Z) \\ &= \frac{1}{n} \int \frac{1}{h^2} K^2 \left(\frac{x-s}{h} \right) f(s) ds - \frac{1}{n} \left[\int K(t) f(x-h t) dt \right]^2 \\ &= \frac{1}{nh} \int K^2(t) f(x-h t) dt - \frac{1}{n} \left[\int K(t) f(x-h t) dt \right]^2 \end{aligned}$$

Continuación

$$\begin{aligned}\frac{1}{h} \int K^2(t) f(x - ht) dt &= \\ &= \frac{1}{h} \int K^2(t) \{f(x) + O(ht)\} dt \\ &= \frac{\|K\|_2^2}{h} f(x) + O(1).\end{aligned}$$

siendo $\|K\|_2^2 = \int K^2(t) dt$. Por lo tanto, reemplazando

$$\begin{aligned}\mathbb{V}\text{ar}[\hat{f}_h(x)] &= \frac{1}{n} \left\{ \frac{\|K\|_2^2}{h} f(x) + O(1) - O(1) \right\} \\ &= \frac{\|K\|_2^2}{nh} f(x) + O(n^{-1}) \\ &= \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1}),\end{aligned}$$

ya que $n^{-1} = o((nh)^{-1})$.

Compromiso Sesgo–Varianza

Luego,

$$\mathbb{B}\left(\hat{f}_h(x)\right) = \frac{1}{2}\mu_2(K)f''(x)h^2 + o(h^2)$$

$$\mathbb{V}\left(\hat{f}_h(x)\right) = \frac{\|K\|_2^2}{nh}f(x) + o((nh)^{-1})$$

Compromiso Sesgo–Varianza

Luego,

$$\mathbb{B} \left(\hat{f}_h(x) \right) = \frac{1}{2} \mu_2(K) f''(x) h^2 + o(h^2)$$

$$\mathbb{V} \left(\hat{f}_h(x) \right) = \frac{\|K\|_2^2}{nh} f(x) + o((nh)^{-1})$$

Para n fijo:

$h \rightarrow 0$ implica $E \left(\hat{f}_h(x) \right) \rightarrow f(x)$ y $\mathbb{V} \left(\hat{f}_h(x) \right) \rightarrow \infty$

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{B}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \mathbb{V}\text{ar}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

- El sesgo es proporcional a $h^2 \Rightarrow$ elijamos h pequeña

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

- El sesgo es proporcional a $h^2 \Rightarrow$ elijamos h pequeña
- El sesgo depende de $f''(x)$ que mide la curvatura de f en x

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

- La varianza disminuye a medida que nh crece

Sesgo y Varianza de $\hat{f}_h(x)$

Comprobamos en el caso fácil que para que todo funcione bien deben pasar dos cosas:

- $h \rightarrow 0$
- $nh \rightarrow \infty$
- Se puede probar que bajo condiciones generales del núcleo K

$$\begin{aligned}\mathbb{E}[\hat{f}_h(x)] &\approx \frac{h^2}{2} \mu_2(K) f''(x) \\ \text{Var}[\hat{f}_h(x)] &\approx \frac{1}{nh} \|K\|_2^2 f(x)\end{aligned}$$

- La varianza disminuye a medida que nh crece
- Para disminuir la varianza necesitamos h o n grandes.

Error Cuadrático Medio de $\hat{f}_h(x)$

Compromiso Sesgo-Varianza

Tenemos que

$$\text{MSE}[\hat{f}_h(x)] = (\mathbb{B}[\hat{f}_h(x)])^2 + \text{Var}[\hat{f}_h(x)]$$

Por otro lado:

$$\mathbb{B}[\hat{f}_h(x)] \approx \frac{h^2}{2} \mu_2(K) f''(x)$$

$$\text{Var}[\hat{f}_h(x)] \approx \frac{1}{nh} \|K\|_2^2 f(x)$$

$$\Rightarrow \text{MSE}[\hat{f}_h(x)] \approx \frac{h^4}{4} \mu_2^2(K) (f''(x))^2 + \frac{1}{nh} \|K\|_2^2 f(x)$$

Si $h \rightarrow 0$ y $nh \rightarrow \infty$, entonces $\text{MSE}[\hat{f}_h(x)] \rightarrow 0$.

Compromiso Sesgo-Varianza \longleftrightarrow relación con sobreajuste

Error Cuadrático Integrado y Medio Integrado de \hat{f}_h

Como medida global: Error Cuadrático Integrado

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: Error Cuadrático Medio Integrado

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Error Cuadrático Integrado y Medio Integrado de \hat{f}_h

Como medida global: Error Cuadrático Integrado

$$\text{ISE}[\hat{f}_h] = \int \left(\hat{f}_h(x) - f(x) \right)^2 dx$$

Como medida global: Error Cuadrático Medio Integrado

$$\text{MISE}[\hat{f}_h] = \int \text{MSE}[\hat{f}_h(x)] dx$$

Asintóticamente: Error Cuadrático Medio Integrado Asintótico

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} \mu_2^2(K) \int (f''(x))^2 dx + \frac{1}{nh} \|K\|_2^2$$

Error Cuadrático Medio Integrado de \hat{f}_h

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} \mu_2^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

- Notemos que es una función de la ventana h .
- Derivando a AMISE respecto de h e igualando a 0, obtenemos que el valor de h que minimiza el AMISE es

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

Error Cuadrático Medio Integrado de \hat{f}_h

$$\text{AMISE}[\hat{f}_h(x)] = \frac{h^4}{4} \mu_2^2(K) \|f''\|_2^2 + \frac{1}{nh} \|K\|_2^2$$

- Notemos que es una función de la ventana h .
- Derivando a AMISE respecto de h e igualando a 0, obtenemos que el valor de h que minimiza el AMISE es

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}} = \text{algo} * \left(\frac{1}{n} \right)^{\frac{1}{5}} \sim n^{-\frac{1}{5}}$$

Selección de h : Regla de Silverman

El $\text{AMISE}[\hat{f}_h(x)]$ se minimiza en

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

- Silverman propone reemplazar a $\|f''\|_2^2$ por su valor cuando f es normal:

$$\|f''\|_2^2 = \frac{3}{8} \pi^{-1/2} \sigma^{-5} \approx 0.212 \sigma^{-5}$$

y a σ por un estimador $\hat{\sigma}$

Selección de h : Regla de Silverman

El $\text{AMISE}[\hat{f}_h(x)]$ se minimiza en

$$h = \left\{ \frac{\|K\|_2^2}{\mu_2^2(K) \|f''\|_2^2 n} \right\}^{\frac{1}{5}}$$

- Silverman propone reemplazar a $\|f''\|_2^2$ por su valor cuando f es normal:

$$\|f''\|_2^2 = \frac{3}{8} \pi^{-1/2} \sigma^{-5} \approx 0.212 \sigma^{-5}$$

y a σ por un estimador $\hat{\sigma}$

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- Si f es normal, la ventana h_{Sil} es óptima.
- Si f no es normal, h_{Sil} dará una ventana no muy alejada de la óptima cuando la distribución no es muy diferente a la normal.

Selección de h : Regla de Silverman

$$h_{Sil} = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{\frac{1}{5}} \approx 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

- σ puede estimarse por S (sd(datos) en R).
o
- σ puede estimarse por la distancia intercuartil IQR (IQR(datos) en R). Para que coincida con σ bajo la distribución normal debe dividirse por 1.349
- La ventana óptima de acuerdo a la regla de Silverman resulta:

$$h_{Sil} = 1.06 \min \left(S, \frac{IQR}{1.349} \right) n^{-\frac{1}{5}}$$

- Algunos autores sugieren reducir el factor 1.06 a 0.90 para aumentar la posibilidad de detectar bimodalidad. (Explorar bw.nrd y bw.nrd0 en R)

¿Qué hace R?

Sheather, S. J. (2004). Density Estimation, *Statistical Science*, Vol. 19, No. 4, 588-597.

- La ventana óptima que vimos resulta de:

$$h_{Sil} = 1.06 \min\left(S, \frac{IQR}{1.349}\right) n^{-\frac{1}{5}}$$

(bw.nrd)

- Silverman (1986) propone usar la ventana óptima que resulta de:

$$h_{Sil} = 0.9 \min\left(S, \frac{IQR}{1.349}\right) n^{-\frac{1}{5}}$$

así reduciendo el factor se espera poder detectar más fácilmente bimodalidad.

(bw.nrd0)

Otro camino para determinar h

Convalidación Cruzada por Máxima Verosimilitud (CV)

Podríamos elegir la ventana h maximizando la log-verosimilitud
.....pero

- El EMV de h es degenerado, resultando una densidad que da masa $1/n$ a cada uno de los datos.

Otro camino para determinar h


Convalidación Cruzada por Máxima Verosimilitud (CV)

Podríamos elegir la ventana h maximizando la log-verosimilitud
.....pero

- El EMV de h es degenerado, resultando una densidad que da masa $1/n$ a cada uno de los datos.
- Alternativa: maximizar una *pseudo-verosimilitud* computada sacando de los datos una observación a la vez (leave-one-out cross-validation).

Convalidación Cruzada

Para evitar sobreajuste usamos *leave-one-out-Cross-Validation*:
(Fuente: James, Witten, Hastie y Tibshirani, 2013)



Convalidación Cruzada por Máxima Verosimilitud (CV)

- El EMV de h es degenerado: da $h = 0$, resultando una densidad que da masa 1 a cada uno de los datos.
- Alternativa: maximizar una *pseudo-verosimilitud* computada sacando de los datos una observación a la vez (leave-one-out cross-validation).

Si observamos los datos x_1, \dots, x_n

$$h_{CV}^* = \operatorname{argmax}_h \left\{ \frac{1}{n} \sum_{i=1}^n \log \hat{f}_h^{(-i)}(x_i) \right\}$$

siendo $\hat{f}_h^{(-i)}(x_i)$ la densidad estimada en el punto x_i sin utilizar al punto x_i :

$$\hat{f}_h^{(-i)}(x_i) = \frac{1}{(n-1)h} \sum_{j \neq i} K\left(\frac{x_i - x_j}{h}\right)$$

- En general, buscamos el máximo sobre una grilla h_1, \dots, h_q y luego, eventualmente, se refina.

Otra forma de implementar Convalidación Cruzada

Integrated Squared Error

$$\begin{aligned}\text{ISE}[\hat{f}_h(\cdot)] &= \int \left(\hat{f}_h(x) - f(x) \right)^2 dx \\ &= \int \left(\hat{f}_h(x) \right)^2 dx - 2 \int \hat{f}_h(x) f(x) dx \\ &\quad + \int (f(x))^2 dx.\end{aligned}$$

Como el último término no involucra a h , podemos minimizar

$$A = \int \left(\hat{f}_h(x) \right)^2 dx - 2 \int \hat{f}_h(x) f(x) dx$$

Convalidación Cruzada

Bowman (1984) propone estimar a A por

$$\frac{1}{n} \sum_{i=1}^n \int \left(\widehat{f}_h^{(-i)}(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \widehat{f}_h^{(-i)}(x_i)$$

siendo $\widehat{f}_h^{(-i)}(x_i)$ la densidad estimada en el punto x_i sin utilizar al punto x_i :

$$\widehat{f}_h^{(-i)}(x_i) = \frac{1}{(n-1)h} \sum_{j \neq i} K \left(\frac{x_i - x_j}{h} \right)$$

Una versión más simple que se usa en general es:

$$\text{LSCV}(h) = \int \left(\widehat{f}_h(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \widehat{f}_h^{(-i)}(x_i)$$

Convalidación Cruzada

Unbiased (o Least Square) Cross-validation

$$\text{LSCV}(h) = \int \left(\hat{f}_h(x) \right)^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_h^{(-i)}(x_i)$$

Se busca el mínimo sobre una grilla h_1, \dots, h_q y luego, eventualmente, se refina.

(bw.ucv)