

# Cota de Rao–Cramer y Eficiencia

Detalles: ver Apunte de Boente y Yohai.

- Estableceremos la conocida desigualdad de Rao–Cramer que da una cota inferior para la varianza de todo estimador insesgado bajo condiciones de regularidad.
- Veremos luego que, bajo condiciones de regularidad, los EMV alcanzan esta cota asintóticamente.
- Sea  $X_1, \dots, X_n$  i.i.d.  $X_i \sim f(x, \theta)$  con  $\theta \in \Theta$ ,  $X \sim X_i$ , donde  $\Theta$  es un intervalo abierto de  $\mathbb{R}$ . Supongamos además de R1 a R2 que:
  - R3.  $f(x, \theta)$  es dos veces diferenciable respecto de  $\theta$
  - R4. La integral  $\int f(x, \theta) dx$  es dos veces diferenciable respecto de  $\theta$  y estas derivadas son intercambiables con el signo integral.

# Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de  $\theta$  es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

# Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de  $\theta$  es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Bajo **condiciones de regularidad** que vimos el EMV se puede hallar como el cero de

$$\frac{\partial}{\partial \theta} \ell_n(\theta, \mathbf{X}_n) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i, \theta)$$

# Estimador de máxima verosimilitud

Recordemos que el estimador de máxima verosimilitud de  $\theta$  es el valor que maximiza

$$\ell_n(\theta, \mathbf{X}) = \sum_{i=1}^n \log f(X_i, \theta)$$

Bajo **condiciones de regularidad** que vimos el EMV se puede hallar como el cero de

$$\frac{\partial}{\partial \theta} \ell_n(\theta, \mathbf{X}_n) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(X_i, \theta)$$

**Función de score:**

$$\frac{\partial}{\partial \theta} \log f(X, \theta)$$

## Número de Información de Fisher

Notemos que  $\frac{\partial}{\partial \theta} \log f(x, \theta) = \frac{1}{f(x, \theta)} \frac{\partial}{\partial \theta} f(x, \theta)$ . Luego,

$$1 = \int_{-\infty}^{\infty} f(x, \theta) dx \Rightarrow 0 = \frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(x, \theta) dx$$

# Número de Información de Fisher

Notemos que  $\frac{\partial}{\partial \theta} \log f(x, \theta) = \frac{1}{f(x, \theta)} \frac{\partial}{\partial \theta} f(x, \theta)$ . Luego,

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} f(x, \theta) dx \Rightarrow 0 = \frac{\partial}{\partial \theta} \int_{-\infty}^{\infty} f(x, \theta) dx \\ 0 &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} f(x, \theta) dx \\ 0 &= \int_{-\infty}^{\infty} \frac{\partial f(x, \theta) / \partial \theta}{f(x, \theta)} f(x, \theta) dx \\ 0 &= \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx \quad (A) \end{aligned}$$

Luego,

$$\mathbb{E}_{\theta} \left[ \frac{\partial}{\partial \theta} \log f(X, \theta) \right] = 0$$

$\frac{\partial}{\partial \theta} \log f(X, \theta)$  se llama **función de score**.

# Número de Información de Fisher

Derivamos ahora en ambos miembros de (A)

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx + \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx$$

observemos que

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx = \mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right]$$

# Número de Información de Fisher

Derivamos ahora en ambos miembros de (A)

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx + \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx$$

observemos que

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx = \mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right] = I(\theta)$$

$I(\theta)$  **número de información de Fisher de una variable aleatoria.**



# Número de Información de Fisher

Derivamos ahora en ambos miembros de (A)

$$0 = \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx + \int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx$$

observemos que

$$\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log f(x, \theta) \frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) dx = \mathbb{E} \left[ \left( \frac{\partial}{\partial \theta} \log f(X, \theta) \right)^2 \right] = I(\theta)$$

$I(\theta)$  **número de información de Fisher de una variable aleatoria.**

Además tenemos que

$$I(\theta) = - \int_{-\infty}^{\infty} \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) f(x, \theta) dx = -\mathbb{E} \left[ \frac{\partial^2}{\partial \theta^2} \log f(x, \theta) \right]$$

Ejemplo:  $X \sim B(1, \theta)$

$$\log f(x, \theta) = x \log \theta + (1 - x) \log(1 - \theta)$$

$$\frac{\partial}{\partial \theta} \log f(x, \theta) = \frac{x}{\theta} - \frac{1 - x}{1 - \theta}$$


$$\frac{\partial^2}{\partial \theta^2} \log f(x; \theta) = -\frac{x}{\theta^2} - \frac{1 - x}{(1 - \theta)^2}$$

Claramente,

$$\begin{aligned} I(\theta) &= -E \left[ \frac{-X}{\theta^2} - \frac{1 - X}{(1 - \theta)^2} \right] \\ &= \frac{\theta}{\theta^2} + \frac{1 - \theta}{(1 - \theta)^2} = \frac{1}{\theta} + \frac{1}{(1 - \theta)} = \frac{1}{\theta(1 - \theta)} \end{aligned}$$

que aumenta para valores de  $\theta$  cercanos a 0 y 1.

Ejemplo:  $X \sim B(1, \theta)$



# Algunas observaciones

- El número de información indica la curvatura de la función que maximizamos al calcular el EMV en  $\theta$ .
- A mayor curvatura mayor precisión en la estimación.
- El número de información de una muestra de tamaño  $n$ ,  $I_n(\theta)$ , es  $n$  veces el de una muestra de tamaño 1. (ver Apunte de Boente y Yohai)
- Interpretamos  $I_n(\theta)$  como la cantidad de información que nos da la muestra para estimar  $\theta$ .

## Cota de Rao–Cramer

Bajo las condiciones de regularidad **R1** a **R4** , si  $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$  es un estimador insesgado de  $\theta$ , entonces

$$\mathbb{V}ar(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

## Cota de Rao–Cramer

Bajo las condiciones de regularidad **R1** a **R4** , si  $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$  es un estimador insesgado de  $\theta$ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Decimos que un estimador insesgado de  $\theta$ ,  $\hat{\theta}_n$ , es **eficiente** sii su varianza alcanza la cota de Rao–Cramer.

## Cota de Rao–Cramer

Bajo las condiciones de regularidad **R1** a **R4** , si  $\hat{\theta}_n = \hat{\theta}_n(\mathbf{X}_n)$  es un estimador insesgado de  $\theta$ , entonces

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{nI(\theta)}$$

Decimos que un estimador insesgado de  $\theta$ ,  $\hat{\theta}_n$ , es **eficiente** sii su varianza alcanza la cota de Rao–Cramer.

Volviendo al caso binomial:

¿Qué pasa con  $\bar{X}_n$ ?

# Distribución Asintótica del EMV

Consideremos además la siguiente condición

- R5.  $f(x, \theta)$  es tres veces diferenciable respecto de  $\theta$ . Además, para todo  $\theta \in \Theta$ , existen una constante  $c$  y una función  $M(x)$  tal que
- $$\left| \frac{\partial^3}{\partial \theta^3} \log f(x, \theta) \right| \leq M(x), \text{ para todo } \theta_0 - c < \theta < \theta_0 + c \text{ y todo } x$$
- en el soporte de la  $X$  y con  $\mathbb{E}_{\theta_0}[M(X)] < \infty$ .



## Teorema (Video 2)

Si

- se cumplen R1 a R5

•  $\hat{\theta}_n$  un estimador de máxima verosimilitud consistente de  $\theta_0$ ,  
entonces,  $\hat{\theta}_n$  es asintóticamente normal para estimar  $\theta_0$ , o sea,

$$\sqrt{n} \left( \hat{\theta}_n - \theta_0 \right) \xrightarrow{\mathcal{D}} N \left( 0, \frac{1}{I(\theta_0)} \right)$$

## Bosquejo de la demo (Video 2)

Notamos:  $\ell'(\theta) = \frac{\partial \ell_n(\theta, \mathbf{X}_n)}{\partial \theta}$  y  $\ell''(\theta) = \frac{\partial^2 \ell_n(\theta, \mathbf{X}_n)}{\partial \theta^2}$

$$0 = \ell'(\hat{\theta}_n) \approx \ell'(\theta_0) + (\hat{\theta}_n - \theta_0) \ell''(\theta_0)$$

$$(\hat{\theta}_n - \theta_0) \approx \frac{-\ell'(\theta_0)}{\ell''(\theta_0)}$$

$$n^{1/2} (\hat{\theta}_n - \theta_0) \approx \frac{-n^{-1/2} \ell'(\theta_0)}{n^{-1} \ell''(\theta_0)}$$

## Bosquejo de la demo (Video 2)

Primero, consideremos el numerador:

$$\left[ n^{-1/2} \ell'(\theta_0) \right] = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta}$$

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\text{Var}_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = \mathbb{E}_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right]^2 = I(\theta_0)$$

## Bosquejo de la demo (Video 2)

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$

## Bosquejo de la demo (Video 2)

Los sumandos son i.i.d. con

$$\mathbb{E}_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = 0$$

y

$$\mathbb{V}ar_{\theta_0} \left[ \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \right] = I(\theta_0)$$

Luego, por el TCL,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{\partial \log f(X_i, \theta_0)}{\partial \theta} \xrightarrow{\mathcal{D}} N(0, I(\theta_0))$$

Consideremos el denominador. Por la L.G.N

$$-n^{-1} \ell''(\theta_0) = -\frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(X_i, \theta_0)}{\partial \theta^2} \xrightarrow{P} I(\theta_0)$$

y por Slutsky resulta que

$$\sqrt{n} (\hat{\theta}_n - \theta_0) \xrightarrow{\mathcal{D}} N \left( 0, \frac{1}{I(\theta_0)} \right)$$

# Distribución Asintótica del EMV: Método Delta

Sea  $\{Z_n\}_{n \geq 1}$ , una sucesión de variables aleatorias tales que para una sucesión numérica  $a_n \uparrow \infty$

$$a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} Z .$$

Sea  $g : \mathbb{R} \rightarrow \mathbb{R}$  una función de clase  $\mathcal{C}^1$  tal que  $g'(\theta) \neq 0$ , entonces

$$a_n (g(Z_n) - g(\theta)) \xrightarrow{\mathcal{D}} g'(\theta) Z .$$

Dem: Esto resulta de un desarrollo de Taylor. En efecto,

$$g(Z_n) = g(\theta) + g'(\theta_n^*) (Z_n - \theta) ,$$

donde  $\theta_n^*$  es un punto intermedio entre  $Z_n$  y  $\theta$ .

Veamos en primera instancia que entonces  $\theta_n^* \xrightarrow{P} \theta$ . En efecto,

$$|\theta_n - \theta_n^*| < |Z_n - \theta_n| = a_n |Z_n - \theta_n| \frac{1}{a_n} \xrightarrow{P} 0$$

y por lo tanto, por la continuidad de  $g'$   $|g'(\theta_n^*) - g'(\theta)| \xrightarrow{P} 0$ . Luego, usando el Teorema de Slutsky tenemos

$$a_n (g(Z_n) - g(\theta)) = g'(\theta) a_n (Z_n - \theta) \xrightarrow{\mathcal{D}} g'(\theta) Z$$

# Distribución Asintótica del EMV: Método Delta

Por ejemplo, si

$$\sqrt{n}(Z_n - \theta) \xrightarrow{\mathcal{D}} N(0, \sigma^2) .$$

y  $g : \mathbb{R} \rightarrow \mathbb{R}$  una función de clase  $\mathcal{C}^1$  tal que  $g'(\theta) \neq 0$ .

Entonces

$$\sqrt{n}(g(Z_n) - g(\theta)) \xrightarrow{\mathcal{D}} N\left(0, \sigma^2 [g'(\theta)]^2\right)$$

Ejemplo: Volvamos al ejemplo que vimos:

Sea  $X_1, \dots, X_n$  una muestra aleatoria de una población con densidad de la forma

$$f(x, \theta) = (1 - \theta)\mathbb{I}_{(-\frac{1}{2}, 0)}(x) + (1 + \theta)\mathbb{I}_{(0, \frac{1}{2})}(x), \quad -1 < \theta < 1$$

¿Cuál es la distribución asintótica del estimador de momentos generalizado que hallamos usando  $m(\theta) = \mathbb{P}_\theta(X > 0)$ ?

## Teorema

Bajo condiciones de regularidad si

- $\hat{\theta}_n$  un estimador de máxima verosimilitud consistente de  $\theta_0$
- $q(\theta)$  derivable con  $q'(\theta) \neq 0$  para todo  $\theta$ ,

entonces,  $q(\hat{\theta}_n)$  es asintóticamente normal para estimar  $q(\theta)$ , o sea,

$$\sqrt{n} \left( q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left( 0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$



# Teorema

Bajo condiciones de regularidad si

- $\hat{\theta}_n$  un estimador de máxima verosimilitud consistente de  $\theta_0$
- $q(\theta)$  derivable con  $q'(\theta) \neq 0$  para todo  $\theta$ ,

entonces,  $q(\hat{\theta}_n)$  es asintóticamente normal para estimar  $q(\theta)$ , o sea,

$$\sqrt{n} \left( q(\hat{\theta}_n) - q(\theta_0) \right) \xrightarrow{\mathcal{D}} N \left( 0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$

- Decimos que una sucesión de estimadores  $T_n$  de  $q(\theta)$  es **asintóticamente normal y eficiente (A.N.E.)** si

$$\sqrt{n} (T_n - q(\theta_0)) \xrightarrow{\mathcal{D}} N \left( 0, \frac{[q'(\theta_0)]^2}{I(\theta_0)} \right)$$