

Errores Normales

Si los errores además de ser independientes con media 0 y varianza σ^2 , son normales, es decir

$$\epsilon_i \sim N(0, \sigma^2) \quad i = 1, \dots, n$$

el modelo Ω puede formularse de la siguiente forma:

$$\Omega \quad : \quad \mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I})$$

En este caso puede demostrarse que el estimador de máxima verosimilitud de $\boldsymbol{\theta}$ coincide con el de mínimos cuadrados.

(Ejercicio del TP)

Intermezzo

La Normal Multivariata

Normal Multivariada

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**

Se dice que $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$


Normal Multivariada

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**

Se dice que $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

Densidad de $\mathbf{Z} \sim N(\mathbf{0}_2, \mathbf{I}_2)$



Normal Multivariada

Sean $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ **simétrica y definida positiva**

Se dice que $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}$$

Nota: la densidad conjunta depende de \mathbf{x} a través de

$$D^2 = (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$$


cuadrado de la **distancia de Mahalanobis**

Distancia de Mahalanobis

- La distancia de Mahalanobis de un punto \mathbf{x} a la media $\boldsymbol{\mu}$ es D siendo

$$D^2 = (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

- De esta forma, dos puntos tienen la misma distancia de Mahalanobis si están en el mismo elipsoide centrado en $\boldsymbol{\mu}$



Notemos que

- $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^{\mathbf{t}} \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

Notemos que

- $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}$$

- Si $\mathbf{X} \sim N(\mathbf{0}, \text{diag}(\lambda_1, \dots, \lambda_p))$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \lambda_j^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\lambda_j} \right\}$$

Por lo tanto, X_1, \dots, X_p son independientes $X_j \sim N(0, \lambda_j)$.

Notemos que

- $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

- Si $\mathbf{X} \sim N(\mathbf{0}, \text{diag}(\lambda_1, \dots, \lambda_p))$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \lambda_j^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\lambda_j} \right\}$$

Por lo tanto, X_1, \dots, X_p son independientes $X_j \sim N(0, \lambda_j)$.

- En particular, si $\mathbf{X} \sim N(\mathbf{0}, \mathbf{I}_p)$, X_1, \dots, X_p son i.i.d. $N(0, 1)$.

Notemos que

- $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su densidad está dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{|\boldsymbol{\Sigma}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

- Si $\mathbf{X} \sim N(\mathbf{0}, \text{diag}(\lambda_1, \dots, \lambda_p))$

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}}} \frac{1}{\prod_{j=1}^p \lambda_j^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^p \frac{x_j^2}{\lambda_j} \right\}$$

Por lo tanto, X_1, \dots, X_p son independientes $X_j \sim N(0, \lambda_j)$.

- En particular, si $\mathbf{X} \sim N(\mathbf{0}, \mathbf{I}_p)$, X_1, \dots, X_p son i.i.d. $N(0, 1)$.
- Sea $\mathbf{X} = (X_1, \dots, X_p)^t \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces,
 X_1, \dots, X_p son independientes $\iff \boldsymbol{\Sigma}$ es diagonal.

Caso $p = 2$

- Sea $\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \in \mathbb{R}^2$ y $\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$ definida positiva ($|\rho| < 1$)

$$f(\mathbf{x}) = \frac{1}{2\pi} \frac{1}{\sigma_1\sigma_2(1-\rho^2)^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x_1 - \mu_1}{\sigma_1} \right)^2 + \left(\frac{x_2 - \mu_2}{\sigma_2} \right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1} \right) \left(\frac{x_2 - \mu_2}{\sigma_2} \right) \right] \right\}$$

Caso $p = 2$

Densidad

Datos generados

Propiedades

- Si $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ entonces

$$E(\mathbf{X}) = \boldsymbol{\mu} \quad \text{y} \quad \boldsymbol{\Sigma}_{\mathbf{X}} = \boldsymbol{\Sigma}$$

Propiedades

- Si $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ entonces

$$E(\mathbf{X}) = \boldsymbol{\mu} \quad \text{y} \quad \boldsymbol{\Sigma}_{\mathbf{X}} = \boldsymbol{\Sigma}$$

- \mathbf{X} es $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si y sólo si $\mathbf{X} = \mathbf{B}\mathbf{Z} + \boldsymbol{\mu}$, donde $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_p)$ y \mathbf{B} es una matriz de $p \times p$ no singular tal que $\mathbf{B}\mathbf{B}^t = \boldsymbol{\Sigma}$.

Propiedades

- Si $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ entonces

$$E(\mathbf{X}) = \boldsymbol{\mu} \quad \text{y} \quad \boldsymbol{\Sigma}_{\mathbf{X}} = \boldsymbol{\Sigma}$$

- \mathbf{X} es $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si y sólo si $\mathbf{X} = \mathbf{B}\mathbf{Z} + \boldsymbol{\mu}$, donde $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_p)$ y \mathbf{B} es una matriz de $p \times p$ no singular tal que $\mathbf{B}\mathbf{B}^t = \boldsymbol{\Sigma}$.
- Sea $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dada $\mathbf{A} \in \mathbb{R}^{q \times p}$, $rg(\mathbf{A}) = q \implies \mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^t)$.

Casos Particulares

En particular, tenemos que

- Una combinación lineal de las componentes es normal:
Si \mathbf{X} es $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\mathbf{a} \in \mathbb{R}^p$, entonces $\mathbf{a}^t \mathbf{X} \sim N(\mathbf{a}^t \boldsymbol{\mu}, \mathbf{a}^t \boldsymbol{\Sigma} \mathbf{a})$.
- Sea $\mathbf{X}^t = (X_1, \dots, X_p)$ un vector p -dimensional con distribución normal multivariada, luego la distribución marginal de cualquier subconjunto de componentes tiene distribución normal multivariada.
- En particular, cada componente es normal:
Si \mathbf{X} es $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\mathbf{a} = \mathbf{e}_i \in \mathbb{R}^p$ es el i -ésimo vector canónico en \mathbb{R}^p , entonces $\mathbf{e}_i^t \mathbf{X} = X_i \sim N(\mu_i, \sigma_i^2)$, donde $\Sigma_{ii} = \sigma_i^2$.

Relación con la χ^2

- Si \mathbf{X} es $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, entonces

$$(\mathbf{X} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_p^2$$

- ¿Cómo quedaría esto en el caso $N_p(\mathbf{0}, \mathbf{I})$?

Seguimos con el modelo Ω formulado de la siguiente forma:

$$\begin{aligned}\Omega \quad : \quad & \mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2 \mathbf{I}) \\ & \mathbf{X} \in \mathbb{R}^{n \times p}, \text{rango}(\mathbf{X}) = p\end{aligned}$$

En el caso de rango completo, es decir cuando $rg(\mathbf{X}) = p$, obtenemos el siguiente resultado:

Teorema: Supongamos que $\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $rg(\mathbf{X}) = p$, $\boldsymbol{\theta} \in \mathbb{R}^p$. Entonces, si $\hat{\boldsymbol{\theta}}$ es el estimador de mínimos cuadrados de $\boldsymbol{\theta}$, tenemos que

- i) $\hat{\boldsymbol{\theta}} \sim N_p(\boldsymbol{\theta}, \sigma^2(\mathbf{X}^t\mathbf{X})^{-1})$
- ii) $\frac{(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^t(\mathbf{X}^t\mathbf{X})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})}{\sigma^2} \sim \chi_p^2$
- iii) $\hat{\boldsymbol{\theta}}$ y $\frac{(n-p)S^2}{\sigma^2}$ son independientes
- iv) $\frac{(n-p)S^2}{\sigma^2} \sim \chi_{n-p}^2$
- v) $\frac{(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^t(\mathbf{X}^t\mathbf{X})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})}{p S^2} \sim F_{p, n-p}$

Combinaciones Lineales

En el contexto del Modelo Lineal suelen interesarnos estimar o hacer inferencia sobre combinaciones lineales del vector de parámetros.

Así podría interesarnos, hacer un test o un intervalo sobre alguna componente o estimar el valor esperado de la respuesta en un nuevo \mathbf{X}_o .

Si nuestro modelo establece

$$E(Y_o) = \theta_1 X_{o1} + \theta_2 X_{o2} + \cdots + \theta_p X_{op}$$

podríamos tener interés en estimar a $\theta_1 X_{o1} + \theta_2 X_{o1} + \cdots + \theta_p X_{op}$ o testear hipótesis como las siguientes:

$$H_o : \theta_j = 0 \quad \text{vs.} \quad H_1 : \theta_j \neq 0$$

$$H_o : \theta_1 - \theta_2 = 0 \quad \text{vs.} \quad H_1 : \theta_1 - \theta_2 \neq 0$$

$$H_o : \theta_2 = \cdots = \theta_p = 0 \quad \text{vs.} \quad H_1 : \text{existe } j : \theta_j \neq 0$$

Combinaciones Lineales

Esto involucra funciones de la forma

$$\varphi = \mathbf{a}^t \boldsymbol{\theta}$$

que son combinaciones lineales del vector de parámetros.

$$\varphi = \mathbf{a}^t \boldsymbol{\theta} \Rightarrow \hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$$

Podría haber muchos estimadores de una función lineal $\mathbf{a}^t \boldsymbol{\theta}$, si nos enfocamos en los **estimadores lineales** en $\mathbf{Y} = (Y_1, \dots, Y_n)^t$ se puede probar el **Teorema de Gauss–Markov**, que establece que cuando el modelo $E(\mathbf{Y}) = \mathbf{X}\boldsymbol{\theta}$ $\Sigma_{\mathbf{Y}} = \sigma^2 \mathbf{I}$, $\text{rango}(\mathbf{X}) = p$, el estimador $\hat{\psi}$ propuesto es el de menor varianza dentro de los estimadores insesgados lineales en \mathbf{Y} .

(Hay una versión más general para rango $r < p$ y funciones estimables)

Propiedades

Teorema Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rango}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^t \boldsymbol{\theta} \quad \hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$$

- i) $\hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^t \boldsymbol{\theta}$ (Ejercicio)
- ii) $\mathbb{V}(\hat{\varphi}) = \sigma^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)

Propiedades

Teorema Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rango}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^t \boldsymbol{\theta} \quad \hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$$

- i) $\hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^t \boldsymbol{\theta}$ (Ejercicio)
- ii) $\mathbb{V}(\hat{\varphi}) = \sigma^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)
- iii) $\hat{\varphi} \sim N(\varphi, \sigma^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a}) = N(\varphi, \sigma_{\hat{\varphi}}^2)$

Propiedades

Teorema Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\boldsymbol{\theta} \in \mathbb{R}^p$, $\text{rango}(\mathbf{X}) = p$ y definamos

$$\varphi = \mathbf{a}^t \boldsymbol{\theta} \quad \hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$$

- i) $\hat{\varphi} = \mathbf{a}^t \hat{\boldsymbol{\theta}}$ es un estimador insesgado para $\varphi = \mathbf{a}^t \boldsymbol{\theta}$ (Ejercicio)
- ii) $\mathbb{V}(\hat{\varphi}) = \sigma^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a} = \sigma_{\hat{\varphi}}^2$ (Ejercicio)
- iii) $\hat{\varphi} \sim N(\varphi, \sigma^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a}) = N(\varphi, \sigma_{\hat{\varphi}}^2)$
- iv) Sea $\hat{\sigma}_{\hat{\varphi}}^2 = s^2 \mathbf{a}^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{a}$ entonces

$$\frac{(\hat{\varphi} - \varphi)}{\hat{\sigma}_{\hat{\varphi}}} \sim t_{n-p}$$

Estimando cada componente

Estos resultados nos permiten deducir intervalos de confianza o tests para cada uno de los coeficientes del modelo lineal:

Como $\hat{\boldsymbol{\theta}} \sim N_p(\boldsymbol{\theta}, \sigma^2(\mathbf{X}^t\mathbf{X})^{-1})$, si \mathbf{e}_i es el i -ésimo vector canónico, entonces

$$\hat{\theta}_i = \mathbf{e}_i^t \hat{\boldsymbol{\theta}} \sim N(\theta_i, \sigma^2 \mathbf{e}_i^t (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{e}_i)$$

Si llamamos $\Sigma_{\hat{\boldsymbol{\theta}}} = \sigma^2 \mathbf{D}$

$$\hat{\theta}_i \sim N(\theta_i, \sigma^2 d_{ii})$$

siendo d_{ii} el i -ésimo elemento diagonal de \mathbf{D} .

Si para un i fijo quisiéramos testear

$$H_o : \theta_i = 0 \quad \text{vs.} \quad H_1 : \theta_i \neq 0$$

tenemos que bajo H_o

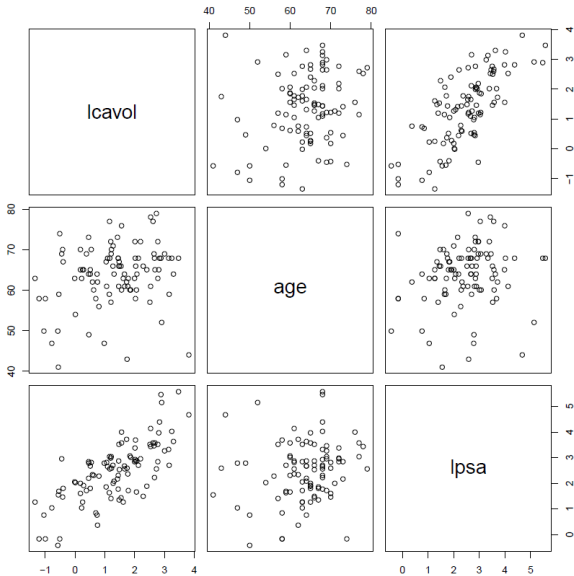
$$\frac{\hat{\theta}_i}{s\sqrt{d_{ii}}} \sim t_{n-p}$$

Por lo tanto, rechazaremos H_o con nivel α si

$$\left| \frac{\hat{\theta}_i}{s\sqrt{d_{ii}}} \right| > t_{n-p, \frac{\alpha}{2}}$$

Vayamos al ejemplo...

Ejemplo



$$lcavol_i = \theta_0 + \theta_1 age_i + \theta_2 lpsa_i + \varepsilon_i$$

```
salida.2 <- lm(lcavol ~ age+lpsa)
```

```
summary(salida.2)
```

$$lcavol_i = \theta_0 + \theta_1 age_i + \theta_2 lpsa_i + \varepsilon_i$$

```
salida.2 <- lm(lcavol ~ age+lpsa)
```

```
summary(salida.2)
```

Call:

```
lm(formula = lcavol ~ age + lpsa) Residuals:
```

Min	1Q	Median	3Q	Max
-2.23487	-0.62467	0.02114	0.54422	1.71757

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-1.50978	0.70670	-2.136	0.0352	*
age	0.01637	0.01112	1.473	0.1442	
lpsa	0.73201	0.07170	10.210	<2e-16	***

Residual standard error: 0.7992 on 94 degrees of freedom

Multiple R-squared: 0.5498, Adjusted R-squared: 0.5402

F-statistic: 57.4 on 2 and 94 DF, p-value: < 2.2e-16

Propiedades

Teorema Supongamos que $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\theta}, \sigma^2\mathbf{I})$, $\text{rango}(\mathbf{X}) = p$, $\boldsymbol{\theta} \in \mathbb{R}^p$.

Sea $\mathbf{A} \in \mathbb{R}^{k \times p}$ con $\text{rango}(\mathbf{A}) = k \leq p$ y definamos

$$\boldsymbol{\psi} = \mathbf{A}\boldsymbol{\theta} \quad \hat{\boldsymbol{\psi}} = \mathbf{A}\hat{\boldsymbol{\theta}}$$

- i) $\hat{\boldsymbol{\psi}}$ es un estimador insesgado para $\boldsymbol{\psi}$
- ii) $\boldsymbol{\Sigma}_{\hat{\boldsymbol{\psi}}} = \sigma^2 \mathbf{A}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t$
- iii) $\hat{\boldsymbol{\psi}} \sim N(\boldsymbol{\psi}, \sigma^2 \mathbf{A}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t) = N(\boldsymbol{\psi}, \boldsymbol{\Sigma}_{\hat{\boldsymbol{\psi}}})$
- iv) Sea $\hat{\boldsymbol{\Sigma}}_{\hat{\boldsymbol{\psi}}} = s^2 \mathbf{A}(\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t$ entonces

$$\frac{(\hat{\boldsymbol{\psi}} - \boldsymbol{\psi})^t \hat{\boldsymbol{\Sigma}}_{\hat{\boldsymbol{\psi}}}^{-1} (\hat{\boldsymbol{\psi}} - \boldsymbol{\psi})}{k} \sim \mathcal{F}_{k, n-p}$$

Ejemplo: Bonus

Vamos a reproducir el cálculo del estadístico F reportado en el summary en el que se testea la significación de la regresión, o sea

$$H_0 : \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Ejemplo: Bonus

Vamos a reproducir el cálculo del estadístico F reportado en el summary en el que se testea la significación de la regresión, o sea

$$H_0 : \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

El vector reducido (es decir sin la primera componente)

$\boldsymbol{\theta}^* = (\theta_1, \theta_2)^t$ es el resultado de multiplicar a $\boldsymbol{\theta} = (\theta_0, \theta_1, \theta_2)^t$ por la matriz

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

Ejemplo: Bonus

Usando las propiedades de vectores aleatorios y de la distribución normal tenemos que

$$\begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \sigma^2 \mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)$$

Ejemplo: Bonus

Usando las propiedades de vectores aleatorios y de la distribución normal tenemos que

$$\begin{pmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}, \sigma^2 \mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)$$

que se puede estimar mediante los siguientes comandos

Ejemplo: Bonus

```
tita.est <- salida.2$coefficients
```

```
ese <- summary(salida.2)$sigma
```

```
XtX = t(model.matrix(salida.2))%*%model.matrix(salida.2)
```

```
XtX.inv = solve(XtX)
```

```
XtX.inv
```

Ejemplo: Bonus

```
tita.est <- salida.2$coefficients
```

```
ese <- summary(salida.2)$sigma
```

```
XtX = t(model.matrix(salida.2))%*%model.matrix(salida.2)
```

```
XtX.inv = solve(XtX)
```

```
XtX.inv
```

	(Intercept)	age	lpsa
(Intercept)	0.781970977	-0.0118329283	-0.0064316618
age	-0.011832928	0.0001934906	-0.0002116456
lpsa	-0.006431662	-0.0002116456	0.0080490331

Ejemplo: Bonus

```
tita.est <- salida.2$coefficients
```

```
ese<- summary(salida.2)$sigma
```

```
XtX = t(model.matrix(salida.2))%*%model.matrix(salida.2)
```

```
XtX.inv = solve(XtX)
```

```
XtX.inv
```

	(Intercept)	age	lpsa
(Intercept)	0.781970977	-0.0118329283	-0.0064316618
age	-0.011832928	0.0001934906	-0.0002116456
lpsa	-0.006431662	-0.0002116456	0.0080490331

```
A<-matrix(rep(0,6),ncol = 3,nrow = 2)
```

```
A[1,2]=A[2,3]=1
```

```
A
```

	[, 1]	[, 2]	[, 3]
[1,]	0	1	0
[2,]	0	0	1

Ejemplo: Bonus

Calculemos $\hat{\theta}^*$

```
theta.star=A%*%tita.est
```

```
theta.star
```

Ejemplo: Bonus

Calculemos $\hat{\theta}^*$

```
theta.star=A%*%tita.est
```

```
theta.star
```

```
           [,1]  
[1,] 0.01637148  
[2,] 0.73201132
```

Ejemplo: Bonus

```
# Calculemos  $\hat{\theta}^*$ 
```

```
theta.star=A%*%tita.est
```

```
theta.star
```

```
           [,1]  
[1,] 0.01637148  
[2,] 0.73201132
```

```
CovMat<- (ese^2)*A%*%solve(XtX)%*%t(A)
```

```
CovMat
```


Ejemplo: Bonus

Calculemos $\hat{\theta}^*$

```
theta.star=A%*%tita.est
```

```
theta.star
```

```
      [,1]  
[1,] 0.01637148  
[2,] 0.73201132
```

```
CovMat<- (ese^2)*A%*%solve(XtX)%*%t(A)
```

```
CovMat
```

```
      [,1]      [,2]  
[1,] 0.0001235781 -0.0001351733  
[2,] -0.0001351733  0.0051407373
```

Ejemplo: Bonus

Dado que

$$V_1 = \frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{\sigma^2} \sim \chi_2^2$$

Ejemplo: Bonus

Dado que

$$V_1 = \frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{\sigma^2} \sim \chi_2^2$$

es independiente de

$$V_2 = \frac{(n-3)s^2}{\sigma^2} \sim \chi_{n-3}^2$$

Ejemplo: Bonus

Dado que

$$V_1 = \frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{\sigma^2} \sim \chi_2^2$$

es independiente de

$$V_2 = \frac{(n-3)s^2}{\sigma^2} \sim \chi_{n-3}^2$$

resulta que el cociente $(V_1/2)/(V_2/(n-3))$ tiene distribución $F_{2,n-3}$

$$\frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{2 s^2} \sim F_{2,n-3}$$

Ejemplo: Bonus

Dado que

$$V_1 = \frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{\sigma^2} \sim \chi_2^2$$

es independiente de

$$V_2 = \frac{(n-3)s^2}{\sigma^2} \sim \chi_{n-3}^2$$

resulta que el cociente $(V_1/2)/(V_2/(n-3))$ tiene distribución $F_{2,n-3}$

$$\frac{(\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)^t \left(\mathbf{A} (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{A}^t \right)^{-1} (\hat{\boldsymbol{\theta}}^* - \boldsymbol{\theta}^*)}{2 s^2} \sim F_{2,n-3}$$

Lo computamos como

Ejemplo: Bonus

```
t(theta.star)%*%(solve(CovMat))%*%(theta.star)/2
```

```
      [,1]  
[1,] 57.40246
```

Ejemplo: Bonus

```
t(theta.star)%*%(solve(CovMat))%*%(theta.star)/2
```

```
      [,1]  
[1,] 57.40246
```

que coincide con el valor reportado en el summary en el F-statistic con 2 y 94 grados de libertad.