


Clasificación

IECD

Problema de Alturas: Problema de Predicción



- Marco de Regresión


1. **Variable de respuesta (Outcome)**

Y : altura de la hija



2. **Covariable (independiente, explicativa, regresora, predictora, feature):**

X : altura de la madre

Estimación No Paramétrica de la Regresión



Estimación No Paramétrica de la Regresión



Otro escenario: ¿Le damos un crédito?

Se quiere predecir si un cliente de un banco pagará un crédito.


Variables registradas:

- X_1 : **balance** (saldo tarjeta)
- X_2 : **income** (ingreso anual)
- X_3 : **student** (si - no)
- $Y = \begin{cases} 1 & \text{(Yes)} & \text{default} \\ 0 & \text{(No)} & \text{c.c.} \end{cases}$

Paquete ISLR

```
> Default
```

	default	student	balance	income
1	No	No	729.52650	44361.625
2	No	Yes	817.18041	12106.135
3	No	No	1073.54916	31767.139
4	No	No	529.25060	35704.494
5	No	No	785.65588	38463.496
6	No	Yes	919.58853	7491.559
7	No	No	825.51333	24905.227
8	No	Yes	808.66750	17600.451
9	No	No	1161.05785	37468.529
10	No	No	0.00000	29275.268
11	No	Yes	0.00000	21871.073
12	No	Yes	1220.58375	13268.562
13	No	No	237.04511	28251.695
14	No	No	606.74234	44994.556
15	No	No	1112.96840	23810.174
16	No	No	286.23256	45042.413
17	No	No	0.00000	50265.312
18	No	Yes	527.54018	17636.540
19	No	No	485.93686	61566.106
20	No	No	1095.07274	26464.631
21	No	No	228.95255	50500.182
22	No	No	954.26179	32457.509
23	No	No	1055.95660	51317.883
24	No	No	641.98439	30466.103
25	No	No	773.21172	34353.314
--			---	---



Foco: Predicción

- $\mathbf{X} = (X_1, X_2, \dots, X_p)$: vector de covariables
- Y : respuesta $\longrightarrow Y = \begin{cases} \text{cuantitativa} & \rightsquigarrow \text{Regresión} \\ \text{cualitativa} & \rightsquigarrow \text{Clasificación} \end{cases}$

Clasificador

- Información disponible $x \in \mathcal{X}$.
- Posibles *etiquetas*. Caso binario $\mathcal{Y} = \{0, 1\}$
- Posibles *etiquetas*. Caso general $\mathcal{Y} = \{y_1, \dots, y_k\}$
- Clasificador: Regla que asigna a $x \in \mathcal{X}$ un posible valor $y \in \mathcal{Y}$.

Clasificación: Marco Teórico

- $X \in \mathcal{X}, Y \in \mathcal{Y}$.
- (X, Y) vector aleatorio, con puntual p_{XY} .
- Clasificador: Regla (de clasificación) que asigna a cada $x \in \mathcal{X}$ un elemento $y \in \mathcal{Y}$

Clasificador $g : \mathcal{X} \rightarrow \mathcal{Y}$

- Error de Clasificación Medio (verdadero - poblacional) del clasificador g

$$L(g) = \mathbb{P}(g(X) \neq Y)$$

- Objetivo (teórico): Encontrar g que minimice el error de clasificación medio


$$g^{op}$$

En la práctica, ¿cómo hacemos?

(X, Y) vector aleatorio

Observamos los datos $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

En la práctica, ¿cómo hacemos?



- Datos:

$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

En la práctica, ¿cómo hacemos?

- $X \in \mathcal{X}, Y \in \mathcal{Y}$.
- Clasificador: $g : \mathcal{X} \rightarrow \mathcal{Y}$

Datos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

- **Error de Clasificación Empírico** del clasificador g :
proporción de pares mal clasificados según g .

en matemática:
$$\hat{L}(g) = \frac{1}{n} \sum_{i=1}^n I_{\{g(x_i) \neq y_i\}}$$

En la práctica, ¿cómo hacemos?

- $X \in \mathcal{X}, Y \in \mathcal{Y}$.
- Clasificador: $g : \mathcal{X} \rightarrow \mathcal{Y}$

Datos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

- **Error de Clasificación Empírico** del clasificador g :
proporción de pares mal clasificados según g .

en matemática:
$$\widehat{L}(g) = \frac{1}{n} \sum_{i=1}^n I_{\{g(x_i) \neq y_i\}}$$

en R: $\text{mean}(g(x) \neq y)$

Clasificación - Ejemplo

Y	0	1
p_Y	0.90	0.10

Clasificación - Ejemplo

Y	0	1
p_Y	0.90	0.10

- $X \in \mathcal{X}$, $Y \in \mathcal{Y}$, (X, Y) vector aleatorio, con puntual p_{XY} .

Y	0	1
$p_{Y X=2}$	0.80	0.20

Y	0	1
$p_{Y X=3}$	0.30	0.70

¿Cómo clasificaríamos con esta información?

Clasificación - Ejemplo

Y	0	1
p_Y	0.90	0.10

- $X \in \mathcal{X}$, $Y \in \mathcal{Y}$, (X, Y) vector aleatorio, con puntual p_{XY} .

Y	0	1
$p_{Y X=2}$	0.80	0.20

Y	0	1
$p_{Y X=3}$	0.30	0.70

¿Cómo clasificaríamos con esta información?

- Clasificador g :

x	.	.	.	2	3
clasificador	.	.	.	0	1

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid X = x) > \mathbb{P}(Y = 1 \mid X = x) \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid X = x) > \mathbb{P}(Y = 1 \mid X = x) \end{cases}$$

Teorema: $\mathbb{P}(g^{op}(X) \neq Y) \leq \mathbb{P}(g(X) \neq Y)$, para todo g .

g^{op} Optimo: Regla de Bayes - Caso binario

$$\begin{aligned}L(g) &= \mathbb{P}(g(X) \neq Y) = E_{XY}[\mathcal{I}_{(g(X) \neq Y)}] \\&= E_X E_{Y|X} [\mathcal{I}_{(g(X) \neq Y)}] \\&= E_X [\mathcal{I}_{(g(X)=0)} \mathbb{P}(Y=1 | X) + \mathcal{I}_{(g(X)=1)} \mathbb{P}(Y=0 | X)] .\end{aligned}$$

Luego, para minimizar $L(g)$ es suficiente con minimizar para todo x

$$\mathcal{I}_{(g(x)=0)} \mathbb{P}(Y=1 | X=x) + \mathcal{I}_{(g(x)=1)} \mathbb{P}(Y=0 | X=x)$$

Teniendo en cuenta que las dos indicadoras son mutuamente excluyentes, alcanza con tomar

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y=1 | X=x) \geq \mathbb{P}(Y=0 | X=x) \\ 0 & \text{si caso contrario} \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid X = x) > \mathbb{P}(Y = 1 \mid X = x) \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid X = x) > \mathbb{P}(Y = 1 \mid X = x) \end{cases}$$

Notemos que

$$\mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \Leftrightarrow \mathbb{P}(Y = 1 \mid X = x) \geq 1/2$$

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq 1/2 \\ 0 & \text{c. c.} \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq \mathbb{P}(Y = 0 \mid X = x) \\ 0 & \text{si c. c.} \end{cases}$$

De Bayes, tenemos que, si X es discreta, en un x de masa positiva

$$\mathbb{P}(Y = y \mid X = x) = \frac{\mathbb{P}(X = x \mid Y = y) \mathbb{P}(Y = y)}{\mathbb{P}(X = x)}$$

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(X = x \mid Y = 1) \mathbb{P}(Y = 1) \geq \mathbb{P}(X = x \mid Y = 0) \mathbb{P}(Y = 0) \\ 0 & \text{si } \mathbb{P}(X = x \mid Y = 0) \mathbb{P}(Y = 0) > \mathbb{P}(X = x \mid Y = 1) \mathbb{P}(Y = 1) \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

En el caso continuo, si $X|Y = 0 \sim f_0$ y $X|Y = 1 \sim f_1$, resulta

$$g^{op}(x) = \begin{cases} 1 & \text{si } f_1(x)\mathbb{P}(Y = 1) \geq f_0(x)\mathbb{P}(Y = 0) \\ 0 & \text{si c. c.} \end{cases}$$

Estimadores Plug-in

Otra vez en el jardín de los senderos que se bifurcan...

Estimación g^{op} Optimo: Métodos discriminativos

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq 1/2 \\ 0 & \text{si c. c.} \end{cases}$$

Aquí se estima

- $\mathbb{P}(Y = 1 \mid X = x)$.

Estimación g^{op} Optimo: Métodos generativos

$$g^{op}(x) = \begin{cases} 1 & \text{si } f_1(x)\mathbb{P}(Y = 1) \geq f_0(x)\mathbb{P}(Y = 0) \\ 0 & \text{si c. c.} \end{cases}$$

Se estiman

- f_0 y f_1
- $p_1 = \mathbb{P}(Y = 1)$ o $p_0 = \mathbb{P}(Y = 0)$.

¿Cómo computamos la regla de clasificación?

Estimación de g^{op} en el **caso discriminativo**.

- X v.a. discreta
- Posibles *etiquetas*. Caso binario $\mathcal{Y} = \{0, 1\}$
- Clasificador: Regla que asigna a cada $x \in \mathcal{X}$ un elemento $y \in \mathcal{Y}$
- g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq 1/2, \\ 0 & \text{si } c. c. \end{cases}$$

¿Cómo computamos la regla de clasificación?

Estimación de g^{op} en el **caso discriminativo**.

- X v.a. discreta
- Posibles *etiquetas*. Caso binario $\mathcal{Y} = \{0, 1\}$
- Clasificador: Regla que asigna a cada $x \in \mathcal{X}$ un elemento $y \in \mathcal{Y}$
- g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid X = x) \geq 1/2, \\ 0 & \text{si } c. c. \end{cases}$$


Datos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

Usaremos el método *Plug-in*, pero....

¿cómo podríamos estimar $\mathbb{P}(Y = 1 \mid X = x)$ o $\mathbb{P}(Y = 0 \mid X = x)$?


Un método democrático: regla de la mayoría

X discreta




Un método democrático: regla de la mayoría

X discreta



Un método democrático: regla de la mayoría


X discreta



$$\frac{\sum_{i=1}^n y_i I_{\{x_i=x\}}}{\sum_{i=1}^n I_{\{x_i=x\}}}$$


Un método democrático: regla de la mayoría

X continua





Un método democrático: regla de la mayoría

X continua



Un método democrático: regla de la mayoría

X continua



k —Vecinos más cercanos (k NN: k -nearest neighbours)

El método de k —Vecinos más cercanos es uno de los métodos existentes para estimar la distribución condicional de Y dado X y para después clasificar una observación en la clase con la mayor probabilidad estimada.

- Elegimos k un entero positivo y un punto x para clasificar.
- El clasificador k NN identifica el conjunto de los k puntos más cercanos a x . Sea N_x dicho conjunto.
- Estima a $\mathbb{P}(Y = 1 \mid X = x)$ por la fracción de puntos en N_x cuya etiqueta es igual a 1:

$$\hat{\mathbb{P}}(Y = 1 \mid X = x) = \frac{1}{k} \sum_{i \in N_x} \mathcal{I}_{\{y_i=1\}}$$

- Análogamente estimamos $\mathbb{P}(Y = 0 \mid X = x)$

¿Cómo elegimos el parámetro k ?

Otra forma: estimación por núcleos

Otra manera de estimar a $\mathbb{P}(Y = 1 \mid X = x)$ podría ser considerar un entorno $(x - h, x + h)$ y repetir el procedimiento anterior.

- Elegimos $h > 0$ y un punto x para clasificar.
- El clasificador identifica en el intervalo $(x - h, x + h)$ los puntos con etiqueta 1 y 0
- Estima a $\mathbb{P}(Y = 1 \mid X = x)$ por la fracción de puntos en $(x - h, x + h)$ cuya etiqueta es igual a 1:

$$\hat{\mathbb{P}}(Y = 1 \mid X = x) = \frac{\sum_{i=1}^n y_i I_{(x-h, x+h)}(x_i)}{\sum_{i=1}^n I_{(x-h, x+h)}(x_i)}$$

¿Cómo elegimos el parámetro h ?

Otra forma: estimación por núcleos

Otra manera de estimar a $P(Y = 1 \mid X = x)$ podría ser considerar un entorno $(x - h, x + h)$ y repetir el procedimiento anterior.

- Elegimos $h > 0$ y un punto x para clasificar.
- El clasificador identifica en el intervalo $(x - h, x + h)$ los puntos con etiqueta 1 y 0
- Estima a $P(Y = 1 \mid X = x)$ usando un núcleo K

$$\hat{\mathbb{P}}(Y = 1 \mid X = x) = \frac{\sum_{i=1}^n y_i K\left(\frac{x - x_i}{h}\right)}{\sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)}$$

¿Cómo elegimos el parámetro h ?

Estimación g^{op} Optimo: Métodos generativos

$$g^{op}(x) = \begin{cases} 1 & \text{si } f_1(x) \mathbb{P}(Y = 1) \geq f_0(x) \mathbb{P}(Y = 0) \\ 0 & \text{si c. c.} \end{cases}$$

Se estiman

- f_0 y f_1
- $p_1 = \mathbb{P}(Y = 1)$ o $p_0 = \mathbb{P}(Y = 0)$.

Regla plug-in de Bayes

- (X, Y) vector aleatorio
- Datos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
- Estimaciones de p_1 y p_0 : $\hat{p}_1 = \frac{n_1}{n}$ y $\hat{p}_0 = \frac{n_0}{n}$, donde $n_j = \#\{y_i = j\}, j = 0, 1$.

Regla plug-in de Bayes

- (X, Y) vector aleatorio
- Datos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
- Estimaciones de p_1 y p_0 : $\hat{p}_1 = \frac{n_1}{n}$ y $\hat{p}_0 = \frac{n_0}{n}$, donde $n_j = \#\{y_i = j\}, j = 0, 1$.
- Estimamos $f_1(x)$ mediante $\hat{f}_1(x)$.
- Estimamos $f_0(x)$ mediante $\hat{f}_0(x)$.
- Hacemos un plug-in en la regla $g^{op}(x)$:

$$\hat{g}(x) = \begin{cases} 1 & \text{si } \hat{f}_1(x) \hat{p}_1 \geq \hat{f}_0(x) \hat{p}_0, \\ 0 & \text{si c.c.} \end{cases}$$

¿Cómo obtenemos las densidades estimadas $\hat{f}_1(x)$ y $\hat{f}_0(x)$?

¿Cómo obtenemos las densidades estimadas $\hat{f}_1(x)$ y $\hat{f}_0(x)$?

Opción 1: Enfoque No Paramétrico

- Estimamos $f_1(x)$ no paramétricamente con $\hat{f}_{1,h_1}(x)$
- Estimamos $f_0(x)$ no paramétricamente con $\hat{f}_{0,h_0}(x)$
- Hacemos un plug-in en la regla $g^{op}(x)$:

$$\hat{g}_{h_0,h_1}(x) = \begin{cases} 1 & \text{si } \hat{f}_{1,h_1}(x) \hat{p}_1 \geq \hat{f}_{0,h_0}(x) \hat{p}_0, \\ 0 & \text{si c.c.} \end{cases}$$

- $h_0, h_1 = ?$

¿Cómo elegimos k , h o (h_0, h_1) ?

En cada caso, tenemos una \hat{g}_t , ¿cómo elegimos el parámetro o vector de parámetros t ?

¿Cómo elegimos k , h o (h_0, h_1) ?

En cada caso, tenemos una \hat{g}_t , ¿cómo elegimos el parámetro o vector de parámetros t ?

Dividiendo los datos....

Test Error

Podemos repetir el mismo razonamiento que hicimos para regresión:

- $\hat{m}_{\mathcal{M}} : \hat{m}$ estimador construido a partir de \mathcal{M}
- Test Error

$$\text{Error}_{\mathcal{M}} = \mathbb{E} [(Y_o - \hat{m}_{\mathcal{M}}(X_o))^2 \mid \mathcal{M}]$$

Test Error

Podemos repetir el mismo razonamiento que hicimos para regresión:

- $\hat{g}_{\mathcal{M}} : \hat{g}$ regla construida a partir de \mathcal{M}
- Test Error

$$\text{Error}_{\mathcal{M}} = \mathbb{E} [(Y_o - \hat{g}_{\mathcal{M}}(X_o))^2 \mid \mathcal{M}]$$

Test Error

Podemos repetir el mismo razonamiento que hicimos para regresión:

- $\hat{g}_{\mathcal{M}} : \hat{g}$ regla construida a partir de \mathcal{M}
- Test Error

$$\text{Error}_{\mathcal{M}} = \mathbb{E} [(Y_o - \hat{g}_{\mathcal{M}}(X_o))^2 \mid \mathcal{M}]$$

- equivalente a

$$\mathbb{P}(\hat{g}_{\mathcal{M}}(X_o) \neq Y_o \mid \mathcal{M})$$

Muchos Datos – Menos Datos

Consideramos las mismas estrategias que ya mencionamos para estimación de la densidad y regresión.

Validación Cruzada: Leave one out - Fórmulas

t : parámetro de tuneo

$$\text{CV}(t) = \widehat{L}(t) = \frac{1}{n} \sum_{i=1}^n L_i(t)$$

- Regresión:

$$L_i(t) = \{Y_i - \widehat{r}_t^{(-i)}(X_i)\}^2$$

$$t_{\text{opt}} = \arg \min_t \widehat{L}(t)$$

- Clasificación:

$$L_i(t) = (Y_i - \widehat{g}_t^{(-i)}(X_i))^2 = \mathcal{I}_{\{\widehat{g}_t^{(-i)}(X_i) \neq Y_i\}}$$

Validación Cruzada: Leave one out - Fórmulas

t : parámetro de tuneo

$$\text{CV}(t) = \widehat{L}(t) = \frac{1}{n} \sum_{i=1}^n L_i(t)$$

- Clasificación:

$$L_i(t) = \mathcal{I}_{\{\widehat{g}_t^{(-i)}(X_i) \neq Y_i\}}$$

Validación Cruzada: K folders - Fórmulas

t : parámetro de tuneo

$$\widehat{L}(t) = \frac{1}{K} \sum_{k=1}^K L_k(t)$$

- Regresión: para el k -ésimo fold

$$L_k(t) = \frac{1}{|\mathcal{T}_k^c|} \sum_{j \in \mathcal{T}_k^c} (Y_j - \hat{r}_{t, \mathcal{T}_k}(X_j))^2$$

$$t_{\text{opt}} = \arg \min \widehat{L}(t)$$

- Clasificación:

$$L_k(t) = \frac{1}{|\mathcal{T}_k^c|} \sum_{j \in \mathcal{T}_k^c} \mathcal{I}_{\{\hat{g}_{t, \mathcal{T}_k}(X_j) \neq Y_j\}}$$

¿Cómo obtenemos las densidades estimadas $\hat{f}_1(x)$ y $\hat{f}_0(x)$?

Opción 2: Enfoque Paramétrico

Por ejemplo, si fuera razonable asumir que la distribución de la altura X en **cada género** es normal, podríamos estimar los parámetros de cada normal con los datos de altura dentro de cada género y hacer un plug-in en la regla de Bayes:

¿Cómo obtenemos las densidades estimadas $\hat{f}_1(x)$ y $\hat{f}_0(x)$?

Opción 2: Enfoque Paramétrico

Por ejemplo, si fuera razonable asumir que la distribución de la altura X en **cada género** es normal, podríamos estimar los parámetros de cada normal con los datos de altura dentro de cada género y hacer un plug-in en la regla de Bayes:

- Obtenemos $\hat{\mu}_1$ y $\hat{\sigma}_1^2$ a partir del género 1: $\Rightarrow \hat{f}_1(x) = f(x, \hat{\mu}_1, \hat{\sigma}_1^2)$.
- Obtenemos $\hat{\mu}_0$ y $\hat{\sigma}_0^2$ a partir del género 0: $\Rightarrow \hat{f}_0(x) = f(x, \hat{\mu}_0, \hat{\sigma}_0^2)$.
- Hacemos un plug-in en la regla $g^{op}(x)$:

$$\hat{g}(x) = \begin{cases} 1 & \text{si } f(x, \hat{\mu}_1, \hat{\sigma}_1^2) \hat{p}_1 \geq f(x, \hat{\mu}_0, \hat{\sigma}_0^2) \hat{p}_0, \\ 0 & \text{si c.c.} \end{cases}$$

Algunas otras cuestiones en Regresión y Clasificación

- ¿Qué pasa en mayor dimensión? Maldición de la Dimensión
- Clasificación: alternativa inocente Bayes Naive
- Métodos Paramétricos

X de mayor dimensión: ingredientes

Supongamos que disponemos de un conjunto de elementos que pueden venir de dos poblaciones distintas.

En cada elemento se ha observado una X variable aleatoria de dimensión p . (por ejemplo registramos altura, ancho, peso, etc.

Se desea clasificar un nuevo elemento, con valores de las variables conocidas.

X de mayor dimensión

Supongamos que para predecir el género del individuo tenemos en cuenta $p = 4$ medidas: altura, peso, perímetro de caderas y de cintura.

(Y, \mathbf{X}) : donde $\mathbf{X} = (X_1, X_2, \dots, X_p)^t$, es decir, se registran p covariables.

Igual que antes el clasificador óptimo

$$g^{op}(\mathbf{x}) = \begin{cases} 1 & \text{si } f_1(\mathbf{x})p_1 \geq f_0(\mathbf{x})p_0, \\ 0 & \text{si c.c.} \end{cases}$$

donde $f_1(\mathbf{x})$ y $f_0(\mathbf{x})$ son densidades en dimensión p .

X de mayor dimensión

Opción 1: Enfoque No Paramétrico

Si no sabemos nada sobre las dos densidades, una alternativa es usar el estimador no paramétrico de la densidad al igual que antes. Ahora tenemos una densidad sobre \mathbb{R}^p : $f(\mathbf{x})$, $\mathbf{x} \in \mathbb{R}^p$.

Dada la

$$\hat{f}(\mathbf{x}) = \frac{1}{nh^p} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{X}_i}{h}\right)$$

ahora $\mathbf{x} - \mathbf{X}_i$ es de dimensión p .

Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes.

Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes. Luego, pensamos que

$$d(\mathbf{x}) = d_1(x_1) d_2(x_2) \dots d_p(x_p)$$

y estimamos:

$$\hat{d}(\mathbf{x}) = \hat{d}_1(x_1) \hat{d}_2(x_2) \dots \hat{d}_p(x_p)$$

Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes. Luego, pensamos que

$$d(\mathbf{x}) = d_1(x_1) d_2(x_2) \dots d_p(x_p)$$

y estimamos:

$$\hat{d}(\mathbf{x}) = \hat{d}_1(x_1) \hat{d}_2(x_2) \dots \hat{d}_p(x_p)$$

Es decir, en lugar de estimar la densidad multivariada de $\mathbf{X} = (\text{altura, peso, perímetro de caderas, perímetro de cintura})$. Estimamos de forma separada la densidad de $X_1 = \text{altura}$, $X_2 = \text{peso}$, $X_3 = \text{perímetro de caderas}$ y $X_4 = \text{perímetro de cintura}$.

Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes. Luego, pensamos que

$$d(\mathbf{x}) = d_1(x_1) d_2(x_2) \dots d_p(x_p)$$

y estimamos:

$$\hat{d}(\mathbf{x}) = \hat{d}_1(x_1) \hat{d}_2(x_2) \dots \hat{d}_p(x_p)$$

Es decir, en lugar de estimar la densidad multivariada de $\mathbf{X}=(\text{altura, peso, perímetro de caderas, perímetro de cintura})$. Estimamos de forma separada la densidad de $X_1 = \text{altura}$, $X_2 = \text{peso}$, $X_3 = \text{perímetro de caderas}$ y $X_4 = \text{perímetro de cintura}$.

Bayes Naive

Así, obtenemos $\hat{f}_1(\mathbf{x})$ y $\hat{f}_0(\mathbf{x})$ y con esto armamos el clasificador.

$$\hat{g}(\mathbf{x}) = \begin{cases} 1 & \text{si } \hat{f}_1(\mathbf{x})\hat{p}_1 \geq \hat{f}_0(\mathbf{x})\hat{p}_0, \\ 0 & \text{si c.c.} \end{cases}$$